
Resumen Investigación Operativa

Ciclo Lectivo 2025

Índice

Unidad 1: Metodología de la Investigación Operativa	4
1 - Introducción	4
2 - Breve historia de la IO	5
3 - Los modelos utilizados en IO	5
4 - Clasificación de los modelos	6
5 - Las limitaciones de los modelos matemáticos	8
6 - Metodología científica de los modelos matemáticos	9
7 - IO Hard y Soft	9
Unidad 2 : Programación Lineal	10
Ejemplo introductorio	10
Un poco de teórico	12
¿Qué es un modelo de programación lineal?	14
Clasificación de las soluciones de un PL y conceptos importantes	15
Teoremas de las combinaciones lineales convexas de soluciones factibles	17
Formas de resolver un problema de PL	18
Método gráfico	18
Unidad 3: Programación Lineal - Método simplex	19
Tips para el método	24
Técnica de la base artificial y simplex para casos de minimización	25
Casos particulares en programación lineal	26
Diagrama de flujo de resolución del método simplex	28
Interpretación de simplex - Análisis económico	29
Breve resumen	35
Unidad N°4: Dualidad y Análisis de sensibilidad	36
Precio Sombra	36
Variables Duales (Precio Sombra)	37
Dualidad	38
¿Cómo pasar de uno al otro?	38
Dualidad Canónica	38
Teorema Débil de Holguras Complementarias	39
Dualidad Mixta	40
Análisis de Sensibilidad	41
Sobre qué parámetros se realiza?	41
Efecto en el gráfico	41
Cálculo de los intervalos de los coeficientes para ci	44
Cálculo de los intervalos de los VLD (bi)	45

Tabla resumen	46
Nueva Variable	47
Unidad N°5: Programación no lineal	48
Características generales de la PNL	49
Tipos de programas no lineales	50
Precio sombra vs. Multiplicador de Lagrange (pregunta de examen)	52
Unidad N°6: Modelos de Redes de Programación Lineal	53
Conceptos Básicos	53
Grafo o Red	53
Representación Gráfica de una Red	53
Camino por los Arcos	53
Valor de un Camino por los Arcos	54
Camino por los Vértices	54
Valor de un Camino por los Vértices	54
Teorema de la Optimidad	54
Caminos de Valor Mínimo	55
Algoritmo de Dijkstra	55
Ejemplo de Aplicación de Dijkstra	55
Árbol de Expansión Mínima	57
Ejemplo de Aplicación de Árbol de Expansión Mínima	58
Problema de Flujo Máximo	60
Unidad 7: Pronósticos	61
Etapas del pronóstico	61
Métodos Cuantitativos de Pronóstico	61
Series de Tiempo	61
Error de Pronóstico	62
Precisión del Pronóstico	63
Método del Pronóstico del Último Valor	63
Método del Promedio	64
Método de Promedios Móviles	64
Método de Promedio Móvil Ponderado	64
Método de Suavizado Exponencial	64
Pronóstico en Presencia de Tendencia	65
Pronóstico en Presencia de Tendencia y Estacionalidad	65
Cálculo de los índices estacionales con Promedio Móvil Centrado	65
Cálculo de los índices estacionales con promedios simples anuales.	66
Descomposición del Pronóstico con componentes de Tendencia y Estacionalidad	66
Señal de Control	67
Control de Errores de Pronóstico	67

Señal de Rastreo	67
Métodos Causales	67
Métodos Cualitativos de Pronóstico	67
Método Delphi	68
Juicio Experto	68
Redacción de Escenarios	68
Unidad N°8: Gestión de Stock	69
Clasificación ABC	69
Simbología a utilizar	70
Modelos Determinísticos	71
Modelo 1 de Universo Cierto o Modelo Sin Ruptura o Modelo CEP o Modelo Básico o como diga el profe.	71
Supuestos	71
Gráfica de comportamiento del inventario	72
Desarrollo	72
Modelo 2 de Universo Cierto o Modelo Con Ruptura	73
Supuestos	73
Gráfica de comportamiento del inventario	74
Desarrollo	74
Relación entre el Modelo 1 y el Modelo 2	75
Modelo con Reabastecimiento Uniforme	75
Supuestos	76
Gráfica de comportamiento del inventario	76
Desarrollo	76
Nivel de Reorden y Stock de Seguridad	77
Periodo de Adelanto Determinista	77
Modelo Sin Ruptura	77
Modelo Con Ruptura	78
Modelo Con Reabastecimiento Uniforme	78
Periodo de Adelanto Aleatorio	79
Modelo Sin Ruptura	79
Modelo Con Ruptura	79
Modelo con Reabastecimiento Uniforme	80
Modelo Con Descuentos Por Compras En Cantidades	80
Desarrollo	80
Gráfica de comportamiento del inventario	81
Modelo 1 de Universo Aleatorio	81
Supuestos	81
Gráfica del comportamiento del inventario	82

Desarrollo	82
Modelo 2 de Universo Aleatorio	82
Supuestos	82

Unidad 1: Metodología de la Investigación Operativa

1 - Introducción

La Investigación Operativa surge como una metodología desarrollada para estudiar problemas de decisión de naturaleza compleja. Su función es ayudar al tomador de decisiones (gerente, administrador), proporcionándole información calificada para la formulación de políticas y estrategias necesarias para la gestión.


La IO se desarrolló a partir de los grandes éxitos obtenidos mediante su aplicación a la resolución de problemas de organización militar durante la Segunda Guerra Mundial.

Definición de Investigación Operativa (según Lawrence y Pasternak):

“Es un enfoque científico para la toma de decisiones ejecutivas, que consiste en:

- *El arte de modelar situaciones complejas*
- *La ciencia de desarrollar técnicas de solución para resolver dichos modelos.*
- *La capacidad para comunicar efectivamente los resultados.”*

Se puede caracterizar como una metodología interdisciplinaria que para su aplicación se requiere de objetividad, racionalidad, creatividad y una actitud de cuestionamiento crítico permanente. La idea de esto es recurrir a un proceso racional cuando el problema a resolver es complejo, ya que en estos casos la intuición no es suficiente.



2 - Breve historia de la IO

Los orígenes de la Investigación Operativa (IO) se remontan a la Segunda Guerra Mundial en Gran Bretaña, donde equipos multidisciplinarios de científicos (incluyendo matemáticos, ingenieros y físicos) fueron convocados para resolver problemas tácticos y estratégicos. Un ejemplo concreto fue la optimización del despliegue de radares y operaciones de bombardeo, donde mediante análisis cuantitativo se determinó que ajustando la altura de detonación de las bombas se podría cuadruplicar su efectividad contra submarinos alemanes.

Tras estos éxitos, Estados Unidos adoptó estos métodos para problemas logísticos complejos, como la planificación óptima de campos minados navales en el Pacífico. El punto de inflexión llegó en 1947 con el desarrollo del Método Símples por George Dantzig, que permitió por primera vez resolver sistemáticamente problemas de asignación de recursos. Por ejemplo, una fábrica de automóviles podía ahora calcular exactamente cuántas unidades producir en cada planta para minimizar costos de transporte.

El desarrollo paralelo de las computadoras digitales en los años 50 y 60 potenció exponencialmente estas técnicas. Un caso emblemático fue la aerolínea American Airlines, que en 1965 implementó el primer sistema computarizado de reservas (SABRE), optimizando en tiempo real la ocupación de vuelos y marcando el inicio de la IO aplicada a servicios. Desde entonces, la IO ha evolucionado para abordar desafíos modernos como la logística de entregas de e-commerce o la gestión inteligente de semáforos en ciudades, demostrando que los principios desarrollados en aquellos laboratorios bélicos siguen transformando nuestra vida cotidiana.

3 - Los modelos utilizados en IO

Una característica esencial del enfoque de la IO es que se basa en el supuesto de la racionalidad, es decir, que las personas y organizaciones optimizan en función de sus expectativas y tienen recursos limitados.

Un elemento esencial en este enfoque cuantitativo es la formulación del modelo matemático, el cual es una representación abstracta de situaciones o problemas reales, a través de símbolos, relaciones o expresiones matemáticas. **La función principal del modelo es deducir**

conclusiones formalmente válidas del problema real a través del estudio del modelo abstracto.

La ventaja que tiene el construir un modelo que represente una situación real es que permite analizar tal situación sin interferir en la operación que se realiza, ya que el modelo es como "un espejo" de lo que ocurre.

Un modelo matemático comprende principalmente tres conjuntos básicos de elementos: variables y parámetros, restricciones y función objetivo.

Las variables y parámetros se pueden clasificar en dos tipos:

- **Exógenas:** Son variables no controlables por el decisor, es decir, sobre las que no se puede influir (como la inflación y la tasa de cambio)
- **Endógenas:** También llamadas **variables de decisión**, son aquellas cuyos valores queremos determinar utilizando el modelo, como por ejemplo los tiempos y materiales necesarios para la fabricación de un producto.

Por otro lado, los parámetros son valores conocidos que relacionan las variables de decisión con restricciones y la función objetivo.

Para tener en cuenta las limitaciones tecnológicas, económicas y otras del sistema, el modelo debe incluir *restricciones* (implícitas o explícitas) que restrinjan las variables de decisión a un rango de valores factibles.

La función objetivo define la medida de efectividad del sistema como una función matemática de las variables de decisión. La solución óptima será aquella que produzca el mejor valor de la función objetivo, *sujeta a las restricciones*. Optimizar es la acción de llevar una cierta magnitud a su óptimo, o sea, a su máximo o a su mínimo, según se trate de algo que se considera beneficioso o perjudicial, solemos usar *maximizar* o *minimizar*.

4 - Clasificación de los modelos

Tenemos en cuenta dos clasificaciones de los modelos de IO: Según los objetivos del problema y según la naturaleza de los datos:

- Clasificación según el **objetivo del problema**:

- **Modelos descriptivos:** Su objetivo es describir o predecir sucesos (nivel de ventas, fechas de terminación de proyectos, número de clientes, etc) dadas ciertas condiciones. Ejemplos de estos modelos son:
 - *Problemas de espera en fila:* Cualquier problema en el que haya que esperar para obtener un servicio, es un problema de este tipo. El objetivo del problema es encontrar una forma de mejorar el rendimiento global del sistema, que se mide normalmente atendiendo al tamaño de la cola, o bien al tiempo que transcurre desde que un cliente llega al sistema hasta que lo abandona.
 - *Problemas de reemplazo,* que se ocupan de decidir el tiempo adecuado para reemplazar los equipos que fallan o se deterioran.
 - *Problemas de planificación y control de proyectos:* El objetivo es determinar la fecha de finalización de un proyecto complejo, como por ejemplo planificaciones de campañas publicitarias, lanzamiento de un nuevo producto, proyectos de ingeniería, etc.
- **Modelos de optimización:** Su objetivo es maximizar cierta cantidad (beneficio, ingresos, eficiencia) o minimizar cierta medida (costo, tiempo) teniendo en cuenta una serie de limitaciones o requisitos que restringen la decisión (disponibilidad de capital, personal, material, etc), algunos ejemplos son:
 - *Problemas de localización:* Como cuando una cadena de supermercados debe decidir en qué barrios abrir 5 nuevas tiendas para reducir los tiempos de entrega a sus clientes frecuentes, analizando patrones de compra y tráfico urbano.
 - *Problemas de mezcla:* Un caso típico es una refinería que combina distintos crudos para producir gasolina premium y regular, asegurando octanajes específicos mientras minimiza el costo total de materia prima.
 - *Problemas de Secuenciación:* Un hospital que debe programar 50 cirugías en 10 quirófanos, coordinando especialistas, equipos y tiempos de recuperación para reducir listas de espera sin saturar al personal.
 - *Problemas de Rutas:* El ejemplo más característico es el clásico Problema del Viajante de Comercio. Un viajante de comercio tiene que visitar N ciudades una y sólo una vez antes de volver a su origen. ¿En qué orden debe visitarlas para minimizar la distancia total viajada?

- *Problemas de Inventario*: Como cuando una farmacia ajusta sus pedidos de medicamentos perecederos: comprar demasiado genera caducidades, pero quedarse corto pone en riesgo a pacientes crónicos.
- Clasificación según la **naturaleza de los datos**: Según la naturaleza de los datos en algunos casos tenemos que ajustar el problema con un **Modelo Determinístico**, en el cuál todos los datos se suponen conocidos, en cambio, en un problema con un **Modelo Estocástico**, tendremos algunos de estos datos inciertos conociendo su probabilidad de ocurrencia. Hay modelos en los que conviene tratar como mixtas estas dos categorías.

5 - Las limitaciones de los modelos matemáticos

La teoría supone que los decisores actúan racionalmente con información perfecta, pero la realidad organizacional muestra que las personas enfrentan información incompleta, percepciones subjetivas y limitaciones de tiempo y recursos. Esto lleva a adoptar decisiones "satisfactorias" más que óptimas, basadas en heurísticas, experiencia personal y sentido común. Además, las decisiones importantes suelen ser colectivas, surgiendo de complejos procesos de negociación donde interactúan factores políticos, relaciones sociales e intereses contrapuestos entre áreas funcionales, lo que muchas veces trasciende los argumentos puramente cuantitativos.

6 - Metodología científica de los modelos matemáticos

La Investigación Operativa surge como una metodología desarrollada para estudiar problemas de decisión de naturaleza compleja, proporcionando información calificada para la formulación de políticas y estrategias de gestión. Su enfoque científico sigue un proceso estructurado que combina rigor analítico con adaptabilidad práctica.

En la etapa de **identificación del problema** y relevamiento de información, el investigador debe comprender profundamente el contexto organizacional mediante entrevistas con stakeholders y análisis de datos históricos. La **formulación del modelo** requiere definir variables clave y parámetros del sistema, creando una representación simplificada pero fiel de la realidad. La **enunciación de hipótesis** explicita los supuestos fundamentales, para saber bajo qué condiciones dicha solución es adecuada, mientras que la **validación del modelo** examina tanto su coherencia interna o [técnica](#), verificando que no se hayan omitido variables o relaciones significativas, también hay una validación [operacional](#), es decir, si los resultados son factibles en el sistema real. Finalmente, la **implementación y seguimiento** aseguran que las soluciones se traduzcan en mejoras concretas, adaptándose continuamente a cambios en el entorno.

7 - IO Hard y Soft

La **IO Hard** se centra en modelos matemáticos cuantitativos, estructurando los problemas a partir de hechos medibles y cuantificables, recurriendo a un modelo matemático para resolver el problema. Por otro lado, la **IO Soft** aborda problemas complejos con componentes subjetivos, utilizando métodos cualitativos como mapas cognitivos para facilitar acuerdos entre grupos. La tendencia actual favorece enfoques multimétodo que integran ambas perspectivas, reconociendo que los problemas organizacionales requieren simultáneamente análisis técnico riguroso y sensibilidad ante factores humanos y políticos. Esta integración permite abordar las dimensiones material, personal y social de los problemas de gestión, combinando el poder de los modelos cuantitativos con la flexibilidad de los enfoques participativos.

Unidad 2 : Programación Lineal

La programación lineal es un modelo de Programación Matemática¹, en la cuál la función a optimizar (maximizar o minimizar) es *lineal* y cuyas variables (no negativas) están sujetas a un conjunto de restricciones también lineales, expresadas como desigualdades del tipo $\geq$, $\leq$ o $=$.

¹Es una representación simplificada de un problema real, expresado en lenguaje matemático (ecuaciones, funciones, variables) para entender el problema, analizar relaciones entre sus componentes y predecir resultados o tomar decisiones óptimas.¹

Representamos un problema utilizando un *modelo matemático*, y ese problema tiene un objetivo, una función objetivo, variables, limitaciones y parámetros.

Ejemplo introductorio

Vamos a poner el ejemplo de una empresa que fabrica cerámicos. Este es el dominio:

“Una fábrica de cerámicos quiere determinar el plan de producción óptimo de sus dos productos: Cerámicos Esmaltados y Cerámicos Rústicos.

El proceso de producción de los cerámicos requiere diferentes combinaciones de horas de mano de obra, horas de secado y de cocción. Para la fabricación de un m² de cerámico esmaltado son necesarias 5 horas de mano de obra, 4 horas de secado y 6 horas de cocción. Por cada m² de cerámico rústico se requieren 5 horas de mano de obra, 8 horas de secado y 4 horas de cocción. La contribución a las utilidades por cada m² de cerámico son: \$8 para el cerámico esmaltado y \$6 para el cerámico rústico

Teniendo en cuenta que la fábrica dispone de 300 horas de mano de obra, 400 horas para secado y 320 horas para cocción por mes, formule un modelo que le permita a la fábrica determinar el plan de producción que maximice la contribución a las utilidades”

	Cerámico Esmaltado	Cerámico Rústico	Disponibilidad hrs. mensuales
Horas de Mano de Obra / m ²	5	5	300
Horas de Secado / m ²	4	8	400
Horas de Cocción / m ²	6	4	320
Contribución a las utilidades / m ²	8	6	

El modelo resuelto es el siguiente:

Objetivo: Maximizar la contribución total a las utilidades mediante la fabricación y venta de cerámicos rústicos y esmaltados.

Variables de decisión:

- x_1 : m² de cerámicos esmaltados a fabricar mensualmente.
- x_2 : m² de cerámicos rústicos a fabricar mensualmente.

Restricciones:

- La cantidad de horas de mano de obra a utilizar mensualmente no debe superar las 300.
- La cantidad de horas de secado a utilizar mensualmente no debe superar las 400.
- La cantidad de horas de cocción a utilizar mensualmente no debe superar las 320.

Es muy importante controlar siempre las unidades de medida a la hora de modelizar.

Finalmente el modelo es:

$$\begin{aligned} \text{Max } z &= 8x_1 + 6x_2 \\ \text{sa} \\ 5x_1 + 5x_2 &\leq 300 && \text{Hs de M O} \\ 4x_1 + 8x_2 &\leq 400 && \text{Hs de Secado} \\ 6x_1 + 4x_2 &\leq 320 && \text{Hs de Cocción} \\ x_1 \text{ y } x_2 &\geq 0 \end{aligned}$$

Viendo las restricciones del problema, vemos que se admite la posibilidad de utilizar una menor cantidad de recursos que los disponibles. Esta situación puede representarse matemáticamente a través de variables que representen los insumos no utilizados, conocidas con el nombre de variables de **holgura** o **excedente**. Estas variables aparecen en la función objetivo con el coeficiente c_j nulo, ya que no aportan a la utilidad. Si la restricción es $\leq$, la holgura se suma y es llamada **variables de excedente**, si es $\geq$ se resta la holgura.

$$\begin{aligned} \text{Max } z &= 8x_1 + 6x_2 + 0S_1 + 0S_2 + 0S_3 \\ \text{sa} \\ 5x_1 + 5x_2 + S_1 &= 300 && \text{Hs de Mano de Obra} \\ 4x_1 + 8x_2 + S_2 &= 400 && \text{Hs de Secado} \\ 6x_1 + 4x_2 + S_3 &= 320 && \text{Hs de Cocción} \\ x_1, x_2, S_1, S_2 \text{ y } S_3 &\geq 0 \\ \text{Siendo:} \\ S_1 &= \text{cantidad de sobrante de horas de mano de obra} \\ S_2 &= \text{cantidad de sobrante de horas de secado.} \\ S_3 &= \text{cantidad de sobrante de horas de cocción.} \end{aligned}$$

En base a estos ejemplos vamos a aclarar unos conceptos importantes acerca de la **formas de representación de los modelos**, uno de ellos servirá luego para el simplex:

Forma	Objetivo	Restricciones
Canónica	max	$\leq$
	min	$\geq$
Estándar	max min	$=$
Mixta	max min	$\leq$; $\geq$; $=$ (mezclados)

Vemos que la primera imagen corresponde al modelo en su forma canónica y la segunda en su forma estándar.

Un poco de teórico

Una vez introducido este ejemplo de un modelo de PL, vamos con el teórico. (zzzzzzz)

Modelo teórico

$Max [Min] Z = f(x)$ “x” es un vector de “n” componentes $\rightarrow n = \text{cant. de variables}$
 $g_i(X) [\leq, \geq, =] b_i \text{ con } i = \{1, 2, \dots, m\}$ “m” representa el número total de restricciones
 (estas son llamadas restricciones **funcionales**)
 $X \geq 0$ Restricción de **no negatividad**

Los modelos de PL tienen dos particularidades:

- Todas las funciones son **lineales**.
- Las variables deben ser **no negativas**.

Ahora bien, los **supuestos** o hipótesis del modelo de PL son:

- **Único objetivo:** A maximizar o minimizar, sujeto a restricciones (sa)
- **Aditividad:** Las contribuciones de los productos individuales son aditivas (sólo sumas)
- **Proporcionalidad:** Tanto la función objetivo como las restricciones deben ser proporcionales al nivel de las variables (relación lineal entre una variable y su contribución individual). (Estas dos hipótesis son las que **nos aseguran la linealidad**)

Ejemplo de proporcionalidad y linealidad (importante para entender luego programacion NO lineal):

Supongamos que una fábrica produce dos tipos de cerámicos: esmaltados (x_1) y rústicos (x_2). La ganancia por cada m^2 de cerámico esmaltado es \$10 y por cada m^2 de cerámico rústico es \$8. Cada m^2 de cerámico esmaltado requiere 5 horas de mano de obra y cada m^2 de cerámico rústico requiere 3 horas. La fábrica dispone de un máximo de 60 horas de mano de obra al mes.

El modelo de Programación Lineal sería:

$$\text{Maximizar } Z = 10x_1 + 8x_2$$

Sujeto a:

$$5x_1 + 3x_2 \leq 60$$

$$x_1 \geq 0, x_2 \geq 0$$

En este ejemplo:

- La función objetivo y la restricción son lineales porque cada término es un coeficiente multiplicado por una variable, y no hay potencias ni productos entre variables.
- Se cumple la proporcionalidad porque, por ejemplo, si se duplican los valores de x_1 y x_2 , tanto la ganancia total como el uso de horas de mano de obra se duplican proporcionalmente.
- **Divisibilidad:** Las variables deben ser individuales a cualquier nivel fraccionario. (ex. Solo puedo tener 0.5 de horas de trabajo hombre)
- **Certidumbre:** Se supone que los parámetros del modelo se conocen con certeza (los parámetros **no varían**)

La PL es un modelo de universo cierto (es decir, determinista), además se dice que es un modelo **formal**, porque puede utilizarse para resolver problemas de cualquier naturaleza en la medida que éstos se puedan formular con la estructura formal que caracteriza a un PL.

Pasos para la formulación de modelos de PL:

1. Definir verbalmente los objetivos, variables, parámetros y restricciones.

2. Armar el modelo, controlando que las unidades que están del lado izquierdo de la restricción coincidan con las unidades del lado derecho.

¿Qué es un modelo de programación lineal?

Un modelo de programación lineal es una *herramienta matemática* que se utiliza para representar y resolver problemas de optimización en los que se busca maximizar o minimizar una función lineal, sujeta a un *conjunto de restricciones* también lineales. Estos modelos *formales* son fundamentales en la toma de decisiones estratégicas dentro de las organizaciones. La idea de todo esto es encontrar **la mejor combinación de las variables** que se encuentren en nuestro problema. Resolver el problema significa encontrar los valores de las variables que cumplan con todas las restricciones del problema y **optimicen** la función objetivo.

Hay dos maneras de resolver este problema:


- a) Gráficamente, resolviendo el SEL de inecuaciones de restricciones y luego con la función objetivo encontrar el óptimo.
- b) Con algún algoritmo, como el método simplex.

Antes de ir con estos métodos vamos a ver las clasificaciones de las soluciones de un modelo de PL.

Clasificación de las soluciones de un PL y conceptos importantes

(Recordar que n = cantidad de variables y m = cant. de restricciones funcionales)


- **Conjunto convexo:** Un conjunto de puntos S es un conjunto convexo, si el segmento rectilíneo que une cualquier par de puntos de S , se encuentra completamente en S . En la siguiente imagen, solamente la última figura es no convexa.




- **Solución Factible** o posible de un PL (SF): Es un conjunto de valores de las variables x_j que **verifican el sistema de restricciones incluidas las de no negatividad** (gráficamente es cualquier punto que está dentro del poliedro de soluciones factibles).
- **Solución Factible Básica (SFB):** Es toda solución factible que tiene como **máximo m variables positivas**; o lo que es lo mismo, **tiene al menos $n-m$ valores de las variables nulos**. El número máximo de soluciones básicas se calcula de la siguiente manera:

$$C_n^m = \frac{n!}{m! \cdot (n-m)!}$$

- **Solución Factible Básica No Degenerada:** Tiene **exactamente m variables positivas**, o **exactamente $n-m$ variables nulas**.
- **Solución Factible Básica Degenerada:** Tiene **menos de m variables positivas**, o **más de $n-m$ variables nulas**.
- **Solución Óptima:** Es toda solución que **le da a la función Z el máximo (o mínimo) valor**.




Ahora van un par de consideraciones respecto al conjunto de soluciones (aplica un poco más a la solución gráfica esto), usamos la solución gráfica del problema de la fábrica de cerámicos.



- Para cumplir con las restricciones de no negatividad se trabaja siempre en el primer cuadrante.
- El poliedro de soluciones es un conjunto convexo.
- Los puntos que resulta necesario considerar para buscar el óptimo, son los que se encuentran sobre la frontera de la región factible.
- Si la PL tiene solución, se encontrará en alguno de los vértices.
- Se puede obtener la solución en cada vértice resolviendo en forma simultánea las ecuaciones lineales que lo determinan.
- Las soluciones factibles en los vértices son soluciones factibles básicas.
- Todos los puntos del poliedro de soluciones verifican las restricciones, es decir que el problema tiene infinitas soluciones factibles.
- En todo punto situado sobre una recta no hay sobrante de ese insumo.
- En las ecuaciones determinantes del óptimo (restricciones limitantes), no hay sobrantes de insumos, por lo tanto, las variables de holgura son nulas.
- En las ecuaciones no determinantes del óptimo (restricciones no limitantes) siempre hay sobrantes de insumos, o sea, las variables de holgura son positivas.
- Si el funcional verifica su máximo valor en un único vértice del poliedro, significa que el problema tiene una única solución óptima.
- Si Z fuera paralela a una restricción limitante, el problema tendría infinitas soluciones óptimas.
- Si el óptimo se verifica en un vértice donde se cruzan 3 o más rectas de restricción, la solución óptima es degenerada.


Teoremas de las combinaciones lineales convexas de soluciones factibles

- **Teorema 1:** “Toda CL convexa de soluciones factibles de un programa lineal, es otra solución factible de dicho programa”
- Corolario: “EL conjunto de todas las SF de una PL, si no es vacío, es un **conjunto convexo**”




Por ser convexo o tiene un solo elemento o infinitos elementos.

- **Teorema 2:** “Si existen más de una SF que le dé valor a la función objetivo, cualquier combinación lineal convexa de los mismos, dará al funcional igual valor” (Se llama a esta recta de iso-utilidad).



Teniendo en cuenta los teoremas 1 y 2: “Cualquier combinación lineal convexa de soluciones factibles óptimas es también una solución factible óptima”.

Por lo tanto, “El conjunto de soluciones factibles óptimas es un conjunto convexo que, si no es vacío, está formado por un elemento o por una infinidad”




- **Teorema 3:** “Si una PL es resoluble, es decir que posee óptimo, existirá siempre por lo menos una SFB que también sea óptima”

Formas de resolver un problema de PL

Método gráfico

1. Graficar las restricciones e identificar el conjunto de soluciones posibles o región factible del problema, usando un punto para verificar la región de soluciones de cada restricción.
2. Trazar la recta representativa de la función objetivo, se le da un valor arbitrario a Z para encontrar su recta, y luego con otro valor verificamos el **sentido de optimidad**.
3. Desplazar la recta en el sentido de optimización hasta identificar el último punto de contacto entre la recta y la región factible. Este punto es la **solución óptima** y corresponde a un vértice del polígono de soluciones. Algo importante es que el **ÓPTIMO DEPENDE DE LA INCLINACIÓN DE Z** .
4. Encontrar los valores de las variables que optimizan la función objetivo, resolviendo de forma simultánea las ecuaciones de restricción que determinan el punto óptimo. Reemplazar estos valores en Z para encontrar su valor.
5. Encontrar los valores de las variables de holgura/excedente, reemplazando los valores de las variables de decisión en cada una de las ecuaciones de restricción.

Se muestra a continuación un resumen de todo esto.



Unidad 3: Programación Lineal - Método simplex

Vamos a trabajar con el caso de los **cerámicos** para resolver un problema de máximo canónico con el método simplex.

Este sería el modelo resuelto, tiene que estar en su forma estándar, **condición necesaria** para aplicar el método simplex, tiene que estar las variables de holgura en la función objetivo, notar que aparecen con el coeficiente $c_j = 0$ ya que no aportan a la utilidad:

$$\begin{aligned} \text{Max } z &= 8x_1 + 6x_2 + 0S_1 + 0S_2 + 0S_3 \\ \text{sa} \quad & 5x_1 + 5x_2 + S_1 = 300 \quad \text{Hs de Mano de Obra} \\ & 4x_1 + 8x_2 + S_2 = 400 \quad \text{Hs de Secado} \\ & 6x_1 + 4x_2 + S_3 = 320 \quad \text{Hs de Cocción} \\ & x_1, x_2, S_1, S_2 \text{ y } S_3 \geq 0 \end{aligned}$$

Siendo:

S_1 = cantidad de sobrante de horas de mano de obra
 S_2 = cantidad de sobrante de horas de secado.
 S_3 = cantidad de sobrante de horas de cocción.

Comenzamos a resolver el problema:

Se busca una primera solución básica igualando a cero x_1 y x_2 , el vector de soluciones quedaría:

$$[x_1=0 \ x_2=0 \ S_1=300 \ S_2=400 \ S_3=320]$$

Quedando entonces $\text{Max } z = 0$

Esto corresponde al punto (0,0) de la solución gráfica.

Vamos a resolver este problema con el método simplex, esta es la tabla que se usa para resolver los problemas:

		$C_b \rightarrow$				
$C_b \downarrow$	Base	VLD	NOMBRE DE LAS VARIABLES			
Z_j						
	$C_j - Z_j$					

Tabla3

- **Columna Base:** Nombre de las variables básicas. Hay un renglón para cada variable básica y este renglón tiene un 1 en la columna que corresponde a dicha variable básica.
- **Columna C_B :** Coeficientes que preceden a las variables básicas en la función objetivo.
- **Fila C_B :** Coeficientes que tienen cada una de las variables en la función objetivo.
- **Columna VLD (vector del lado derecho):** Contiene los valores de las variables básicas en la presente solución y el valor de la función objetivo.
- El **cuerpo de la tabla** contiene tantas filas como ecuaciones de restricción tenga el problema más dos renglones, uno para z_j y otro para $c_j - z_j$ y tantas columnas como variables tenga el problema.
- **Cálculo de la fila z_j :** Se determina cada valor como la suma de los productos que se obtienen multiplicando los elementos de la columna C_B por los elementos correspondientes de la j -ésima columna.
- **Cálculo de la fila $c_j - z_j$:** Se determina cada valor restando z_j de c_j .

		C_B	8	6	0	0	0
C_B	Base	VLD	x_1	x_2	S_1	S_2	S_3
0	S_1	300	5	5	1	0	0
0	S_2	400	4	8	0	1	0
0	S_3	320	6	4	0	0	1
	z_j	0	0	0	0	0	0
	$c_j - z_j$		8	6	0	0	0

Tabla 4

Ésta es la solución de partida, encontrándose en la columna VLD la primera solución:

$$[x_1=0 \ x_2=0 \ S_1=300 \ S_2=400 \ S_3=320 \ Z=0]$$

Este vendría ser nuestro **punto de partida**, ahora pasamos a la segunda etapa del método o **fase iterativa**, en la que analizamos si la solución actual es óptima o no, y en este segundo caso, hallar una nueva solución que le proporcione un mejor valor a la función objetivo.

Para saber si nuestra solución es **óptima**, se utiliza el **criterio de optimalidad**:

- En problemas de **maximización**, la solución es óptima si todas las diferencias $(c_j - z_j)$ son negativas o nulo.
- En problemas de **minimización**, la solución es óptima si todas las diferencias $(c_j - z_j)$ son positivas o nulo.

En este ejemplo, hay dos valores positivos, por lo tanto la solución no es óptima, ahora para encontrar otra SFB, tenemos que tener en cuenta que, alguna de las variables no básicas en la solución actual, deberá **ingresar** a la base y, alguna de las variables básicas deberá **salir** de la base actual (esto es, asumir un valor nulo en la nueva solución).

Hay que tener claro algo muy importante: "Las variables que son iguales a cero en una SFB, se las denomina **variables no básicas** y las que asumen un valor positivo son las variables **básicas** (ya que forman parte de la solución actual)."

Primero se selecciona la variable que ingresa a la base y luego la variable que sale. Se debe seguir el siguiente criterio:

- Si Z es de **Maximización**, ingresa la variable que verifica mayor diferencia marginal ($c_j - z_j > 0$). **Esto indica que si esa variable, el valor de Z aumentará.**
- Si Z es de **Minimización**, ingresa la variable que verifica menor diferencia marginal ($c_j - z_j < 0$ (es decir, el mayor valor negativo). **Esto indica que si esa variable, el valor de Z disminuirá.**

En este caso ingresaría x_1 , y sale de la base la variable que tenga el menor cociente entre su valor actual (λ_i , este vendría a ser la **columna VLD**) y el coeficiente λ_{ij} (siendo $j=k$ la **variable que entra a la base**) siempre y cuando dicho coeficiente sea **estrictamente positivo**, es decir:

$$\theta = \min \frac{\lambda_i}{\lambda_{ij}}; \quad \forall \lambda_{ij} > 0$$

Esto es igual tanto para problemas de **máximo** como para problemas de **mínimo**.

Sale en este caso S_3 : quedando nuestra tabla:

		C_B	8	6	0	0	0	$300/5=60$ $400/4=100$ $320/6=53,33$
C_B	Base	VLD	x_1	x_2	S_1	S_2	S_3	
0	S_1	300	5	5	1	0	0	
0	S_2	400	4	8	0	1	0	
0	S_3	320	6	4	0	0	1	
	z_j	0	0	0	0	0	0	
	$C_j - z_j$		8	6	0	0	0	

Tabla 5

El menor valor de θ me indica el valor máximo que puede tener la variable de entrada, sino nos **estaríamos saliendo de la región factible**.

Ahora tenemos que incorporar x_1 y para calcular la nueva SFB, tendremos como nuevas variables S_1 , S_2 y x_1 y nuestras nuevas variables no básicas serán x_2 y S_3 .

Ahora lo que tenemos que hacer es actualizar el valor de la función objetivo, la nueva solución quedaría:

$$Z_{\text{nuevo}} = Z_0 + (C_j - Z_j)\theta$$

Como x_1 reemplaza a S_3 , la columna correspondiente a x_1 en la nueva tabla deberá ser el vector unitario: $[1 \ 0 \ 0]$

Entonces tenemos que hallar una matriz equivalente a la matriz de la solución anterior, por lo que tendremos que usar operaciones elementales de filas:

1 - Se arma la nueva tabla colocando a x_1 en la base, con su correspondiente columna C_B .

		C_B	8	6	0	0	0
C_B	Base	VLD	x_1	x_2	S_1	S_2	S_3
0	S_1						
0	S_2						
8	x_1						
	Z_j						
		$C_j - Z_j$					

Tabla 6

2 - El número que se encuentra en la intersección entre la columna de la variable que entra y la fila de la variable que sale, se llama elemento **pivot** y en la nueva solución tiene que ser igual a uno.

Para esto aplico operaciones elementales de filas, en este caso e3 (%). Quedando:

		C_B	8	6	0	0	0
C_B	Base	VLD	x_1	x_2	S_1	S_2	S_3
0	S_1						
0	S_2						
8	x_1	320/6	1	4/6	0	0	1/6
	Z_j						
		$C_j - Z_j$					

Tabla 7

3 - Ahora tengo que encontrar los elementos nulos del vector x_1 con operaciones elementales de fila, tenemos que anular los dos elementos restantes, es decir, los de los vectores S_1 y S_2

VLD	x_1	x_2	S_1	S_2	S_3
400	4	8	0	1	0
$+ (320/6)(-4)$	$+ 1(-4)$	$+ (4/6)(-4)$	$+ 0(-4)$	$+ 0(-4)$	$+ (1/6)(-4)$
1120/6	0	32/6	0	0	-4/6

Tabla 8

C_B	Base	VLD	x_1	x_2	S_1	S_2	S_3
0	S_1						
0	S_2	1120/6	0	32/6	0	1	-4/6
8	x_1	320/6	1	4/6	0	0	1/6
	Z_j						
		$C_j - Z_j$					

Tabla 9

Ahora hago esto para S_1 , sumando a la fila S_1 más la nueva fila de x_1 multiplicada por -5:

		C_B	8	6	0	0	0
C_B	Base	VLD	x_1	x_2	S_1	S_2	S_3
0	S_1	200/6	0	10/6	1	0	-5/6
0	S_2	1120/6	0	32/6	0	1	-4/6
8	x_1	320/6	1	4/6	0	0	1/6
	Z_j						
		$C_j - Z_j$					

Tabla 10

4 - Ahora estando actualizada la tabla, calculo la fila de Z_j y la de $C_j - Z_j$ conformando la nueva tabla.

C _B	Base	C _B	8	6	0	0	0	
		VLD	x ₁	x ₂	S ₁	S ₂	S ₃	
0	S ₁	200/6	0	10/6	1	0	-5/6	20
0	S ₂	1120/6	0	32/6	0	1	-4/6	35
8	x ₁	320/6	1	4/6	0	0	1/6	80
	Z _j	1280/3	8	32/6	0	0	8/6	
		C _j - Z _j	0	4/6	0	0	-8/6	

Tabla 11

Quedando la nueva solución: $[x_1=320/6 \ x_2=0 \ S_2=200/6 \ S_2=1120/6 \ S_3=0 \ Z=1280/3]$

Esta solución no es óptima ya que para la columna correspondiente a la variable x_2 se verifica un valor $c_j - z_j > 0$.

La variable que ingresa a la base en la próxima solución será x_2 , ya que verifica la mayor diferencia marginal, $(c_2 - z_2) = 4/6$.

Para determinar la variable que sale de la base calculamos los cocientes entre cada elemento de la columna VLD y los elementos correspondientes de la columna de x_2 , **pero sólo considerando los denominadores positivos**. Los cálculos se pueden observar en la tabla.

Luego se repiten los pasos del 1 al 5 para pasar a la nueva solución, obteniendo la nueva tabla, quedando:

C _B	Base	C _B	8	6	0	0	0	
		VLD	x ₁	x ₂	S ₁	S ₂	S ₃	
6	x ₂	20	0	1	6/10	0	-5/10	
0	S ₂	80	0	0	-32/10	1	2	
8	x ₁	40	1	0	-4/10	0	5/10	
	Z _j	440	8	6	4/10	0	1	
		C _j - Z _j	0	0	-4/10	0	-1	

Tabla 12

Esta ya es la solución óptima ya que todas las diferencias marginales $(c_j - z_j)$ son **negativas o nulas**. Esto es así porque se trata de un problema de **máximo**, si se tratara de un problema de **mínimo**, recordamos que las diferencias marginales deben ser **positivas o nulas**.

La solución óptima es:

$[x_1=40 \ x_2=20 \ S_1=0 \ S_2=80 \ S_3=0 \ Z=440]$

Otra consideración, es que las $c_j - z_j$ que valen cero son básicas, es decir, forman parte de nuestra base (*duh*) (mirar la tabla de arriba para darse cuenta, si en un ejercicio las variables de la base en la fila $c_j - z_j$ son $\neq 0$ hay algo que está mal).

Tips para el método

- **Determinación de la variable que entra:** Si dos variables no básicas empatan en el mejor coeficiente $(C_j - Z_j)$, puedes elegir cualquiera de ellas. Esto cambiará el camino hacia el valor óptimo (Z^*).
- **Determinación de la variable que sale:** Si dos filas empatan en el menor θ , puedes escoger cualquiera. En este caso, la solución factible básica (SFB) será degenerada. Si

no puedes calcular θ porque ningún $\lambda_{ij} > 0$ para la variable que entra, el método Simplex debe detenerse, indicando que el problema es **no acotado**.

- **Solución óptima:**
 - Si una variable básica tiene valor 0, estamos ante una solución factible básica degenerada.
 - Si una variable no básica tiene coeficiente $(C_j - Z_j)$ igual a 0, el problema tiene **múltiples soluciones óptimas**.
- **Errores en las iteraciones:** Si el valor del lado derecho (VLD) resulta negativo, probablemente hubo un error en el cálculo de θ . Es necesario retroceder y revisar los cálculos.
- **Cálculo del valor de la función objetivo en el siguiente punto:** Se obtiene sumando el valor actual de la función objetivo y el producto entre $(C_j - Z_j)$ y θ . Ejemplo: En el paso del punto 3 al 4, si el valor de la función en el punto 3 es 1680, $\theta = 8$ y $C_j - Z_j = 10$, el cálculo sería: $1680 + (10 * 8) = 1760$.
- **Solución degenerada:** Si uno de los valores del lado derecho (VLD) es nulo al llegar a la solución óptima, esto indica que la solución es **degenerada**.
- **$C_j - Z_j$ (Incremento neto unitario en Z):** Si yo incluyo un Incremento neto unitario > 0 mi función objetivo va a crecer, en caso contrario voy a tener una disminución en Z. Para las variables básicas este incremento es siempre **CERO**.

Técnica de la base artificial y simplex para casos de minimización

Para el caso de minimización existen dos formas de tratamiento:

1. Matemáticamente $\text{Min } z = \text{Max } (-z)$, multiplicamos a la función z por (-1) y lo trabajamos como caso de máximo.
2. Trabajarlo como mínimo, cambiar el criterio de optimidad y el criterio para decidir la variable que entra a la base teniendo en cuenta el significado de $c_j - z_j$

Ahora vamos con la técnica de la base artificial, **esta técnica consiste en modificar mi problema original agregando nuevas variables ficticias** (quedando un problema no equivalente al original) en las restricciones, que me permitirá armar la primera SFB, a partir de la cuál podremos iterar. La idea de todo esto es ayudarnos a encontrar la primera SFB para comenzar a aplicar el método simplex, cosa que se **complica cuando es un mínimo**.

Se hace esto porque el algoritmo elimina estos valores arbitrariamente grandes, en caso de un máximo, el algoritmo trataría de eliminar una pérdida excesivamente grande, y en el caso de un mínimo, se eliminaría un costo excesivamente grande.

Se tiene el siguiente problema:

$$\text{Max } z = 100 x_1 + 120 x_2 + 100 x_3$$

s.a.

$$10 x_1 + 10 x_2 + 5 x_3 \geq 350$$

$$12 x_1 + 20 x_2 + 10 x_3 \leq 2200$$

$$15x_1 + 15x_2 + 15x_3 = 1500$$

$$x_1, x_2 \text{ y } x_3 \geq 0$$

Expreso el problema en su forma estándar:

$$\text{Max } z = 100x_1 + 120x_2 + 100x_3 + 0S_1 + 0S_2$$

s.a.

$$10x_1 + 10x_2 + 5x_3 - S_1 = 350$$

$$12x_1 + 20x_2 + 10x_3 + S_2 = 2200$$

$$15x_1 + 15x_2 + 15x_3 = 1500$$

$$x_1; x_2; x_3; S_1 \text{ y } S_2 \geq 0$$

Analizo la matriz de los coeficientes:

10	10	5	-1	0
12	20	10	0	1
15	15	15	0	0

Si en la matriz A no encontramos los m vectores unidad que formarán la base de partida, **debemos agregar nuevas variables para generarlos**, en el caso del problema agregamos 2, ya que tenemos solo 1 vector unidad.

$$\text{Max } z = 100x_1 + 120x_2 + 100x_3 + 0S_1 + 0S_2 - M A_1 - M A_2$$

s.a.

$$10x_1 + 10x_2 + 5x_3 - S_1 + A_1 = 350$$

$$12x_1 + 20x_2 + 10x_3 + S_2 = 2200$$

$$15x_1 + 15x_2 + 15x_3 + A_2 = 1500$$

$$x_1; x_2; x_3; S_1; S_2; A_1 \text{ y } A_2 \geq 0$$

Se agregan sumadas, una por cada restricción en la que se necesite generar el vector unidad.

En Z se deben agregar precedidas por un coeficiente muy grande en valor absoluto:

- En caso de problemas de **maximización**, se restan las variables artificiales en la función objetivo.
- En caso de problemas de **minimización**, se suman las variables artificiales en la función objetivo.
- Máximo -> Negativo muy pequeño
- Mínimo -> Positivo muy grande


Una vez encontrados los “m” vectores unidad con configuración de matriz identidad, se trabaja en el Simplex normalmente. Tener en cuenta que mientras existan variables artificiales en la base, la solución encontrada, **NO es una solución del problema original**.

Si ocurriera que ya no podemos continuar trabajando porque se cumple con la condición de optimidad en $(c_j - z_j)$ y aún quedan variables artificiales en la base a nivel **positivo**, significa que estamos en el caso particular de un **problema Incompatible**.

Si ocurriera que ya no podemos continuar trabajando porque se cumple con la condición de optimidad en $(c_j - z_j)$ y aún quedan variables artificiales en la base a nivel **nulo**, significa que estamos en el caso particular de un **Problema Degenerado**.

Casos particulares en programación lineal

- **Problema incompatible:** cuando no hay intersecciones entre las restricciones (poner fotos). En el simplex lo vemos cuando tenemos restricciones mezcladas.
- **Problema no acotado:** Tiene que ver con el desplazamiento de la función objetivo, es decir, si la desplazo infinitamente y no encuentro un óptimo, entonces es no acotado. En el simplex se ve **cuando ninguna variable sale de la base**, eso sale de la imposibilidad de calcular los θ , viene de la imposibilidad de dividir por cero. En la realidad no existe, ya que **no puedo** aumentar infinitamente mis ganancias o disminuir infinitamente mis costos, si se nos llega a dar este caso, tenemos que replantear nuestro PL, porque **ALGO** hicimos mal.
- **Problema degenerado o con solución degenerada:** Cuando cortan tres restricciones en un alguno de los vértices, es decir, el vértice está **sobredefinido**. En simplex se ve cuando en la columna solución (VLD) tengo un valor cero. **Cuando tenga dos θ iguales, me voy a dar cuenta que la próxima solución va a ser degenerada** (aparece el cero), ¿cuál elijo? La realidad es prueba y error. Aclaremos que no necesariamente es el óptimo, se sigue trabajando en estos casos.
- **Múltiples soluciones óptimas:** En el gráfico lo vemos cuando nuestro Z obtenido es paralelo a una restricción limitante del óptimo. En simplex me doy cuenta que cuando obtengo un $C_j - Z_j$ igual a cero en una variable **no básica**, como es cero, no voy a tener ningún incremento en Z.




- **Caso particular de un caso particular:** Problema degenerado y tengo un 0 en $C_j - Z_j$ no básico, no me garantiza soluciones múltiples, es decir, entra una variable de holgura y sale una variable de holgura. *Si el problema no es degenerado*, entonces puedo afirmar que tiene múltiples soluciones óptimas, en caso contrario hay que ver si hay algún cambio.

Tabla resumen:

Caso particular	Cómo se reconoce gráficamente	Cómo se reconoce en Simplex
Problema incompatible	No hay intersección entre las restricciones; no existe región factible.	Se presentan restricciones que no permiten una solución factible (mezcla de restricciones que se contradicen).
Problema no acotado	La función objetivo puede desplazarse indefinidamente (no hay límite a la mejora del objetivo).	Ninguna variable puede salir de la base: no se pueden calcular los θ por división por cero.
Problema degenerado	Tres o más restricciones se intersectan en un mismo vértice (el vértice está sobredefinido).	En la columna solución (VLD) aparece un valor cero. También puede detectarse si hay dos θ iguales.
Múltiples soluciones óptimas	La recta de la función objetivo es paralela a una restricción activa en el óptimo.	Hay un $C_j - Z_j = 0$ en una variable no básica (indicando otra solución óptima posible).
Degenerado con $C_j - Z_j = 0$	No se distingue gráficamente claramente. Puede confundirse con múltiples soluciones.	Hay un $C_j - Z_j = 0$ en una variable no básica, pero entra y sale una variable de holgura, sin mejora. Solo si el problema no es degenerado, se puede afirmar que hay múltiples soluciones.

Diagrama de flujo de resolución del método simplex



Interpretación de simplex - Análisis económico

Este tema es muy importante para entender el análisis de sensibilidad (tema que sigue).

Usaremos el siguiente caso de ejemplo:

“Supongamos una fábrica que produce dos productos, a los que llamaremos P_1 y P_2

En su proceso productivo utiliza tres insumos escasos:

- ✓ Horas de mano de obra
- ✓ Horas máquina
- ✓ Unidades de materia prima

Conoce la disponibilidad mensual de insumos y la contribución marginal unitaria de cada producto. Además estima que puede vender todos los productos que fabrique.”

Datos del problema:

	P_1	P_2	Disponibilidad
Hs de Mano de obra	10	10	980
Hs de Maquina	12	24	1932
Materia prima	15	10	1250
Utilidad	\$4	\$7	

Modelo de PL:

$$\text{Max } Z = 4x_1 + 7x_2$$

Sa

$$10x_1 + 10x_2 \leq 980 \text{ (hrs. de mano de obra)}$$

$$12x_1 + 24x_2 \leq 1932 \text{ (hrs. máquina)}$$

$$15x_1 + 10x_2 \leq 1250 \text{ (unidades de materia prima)}$$

$$x_j \geq 0, j=1,2$$

x_1 :unidades a producir del producto 1

x_2 :unidades a producir del producto 2

Ahora vemos la segunda tabla de simplex (luego de una iteración)

	C_j		4	7	0	0	0	
C_i	BASE	P_0	P_1	P_2	P_3	P_4	P_5	
0	S_1	175	5	0	1	-10/24	0	$X^A = \begin{bmatrix} 0 \\ 80,5 \\ 175 \\ 0 \\ 445 \end{bmatrix}$ $Z^A = \$563,5$
7	X_2	80,5	0,5	1	0	1/24	0	
0	S_3	445	10	0	0	-10/24	1	
	Z_j	563,5	3,5	7	0	7/24	0	
	$C_j - Z_j$		0,5	0	0	-7/24	0	

De la solución X^A podemos interpretar, que $x_1=0$, no producimos ninguna unidad de x_1 ya que esta variable no está en nuestra base, luego $x_2=80.5$, es decir, estaríamos produciendo 80.5 unidades de el producto 2, $S_1 = 175$ es el sobrante Hs de mano de obra, $S_2=0$ ya que no está en la base y $S_3 = 445$, que son las unidades sobrantes de materia prima. Dando un $Z=\$563.5$

Todavía no tenemos la solución óptima, ya que hay una variable positiva (recordar que para caso de máximo se obtendrá la SFB cuando todos los c_j-z_j son negativas o cero), sería una solución factible básica, no degenerada (3 valores >0 , tantos como restricciones haya, y los restantes nulos).

Analicemos el plan de solución actual:

$$X^A = [0 \quad 80.5 \quad 175 \quad 0 \quad 445]$$

- Se producen 80.5 unidades del producto 2.
- Ninguna unidad del producto 1.
- Hay disponibles 175 HMO y 445 UMP.
- Las HMAq son escasas (se utiliza el total disponible), es decir es un recurso limitante.
- La contribución a las utilidades es de \$563.5.

Ahora, qué sucede si decidimos producir el producto P1. Qué cantidad de recursos necesito para producir una unidad de P1, esto lo podemos ver en la formulación del problema, analizando las restricciones.

$$10x_1 + 10x_2 \leq 980 \text{ (hrs. de mano de obra)}$$

$$12x_1 + 24x_2 \leq 1932 \text{ (hrs. máquina)}$$

$$15x_1 + 10x_2 \leq 1250 \text{ (unidades de materia prima)}$$

Vemos que para producir una unidad de P1 son necesarias 10 HMO, 12 HMAq y 15 UMP. Tenemos disponibilidad de HMO y de UMP, pero se nos agotaron las HMAq. ¿Qué deberíamos hacer entonces? **Dejar de producir algunas unidades de P2.**

En el lado izquierdo de la restricción de las HMA, podemos ver el uso que se le da a ese recurso:

$$12x_1 + 24x_2 \leq 1932 \text{ (hrs. máquina)}$$

Nos tenemos que hacer la siguiente pregunta, Para producir una unidad de P1, es necesario dejar de producir exactamente 1 una unidad de P2? No, con dejar de producir **media unidad** de P2 ya se nos liberan los recursos necesarios para producir una unidad de P1, ($24/2=12$)

$$24 \left[\frac{hs}{u} \right] * \frac{1}{2} [u] = 12hs \text{ necesarias por unidad de P1}$$

Esta información la tenemos también en la tabla simplex en la intersección entre la fila de la variable x_2 y la columna de la variable no básica P1 (x_1), que representa al Producto 1,

C _i	C _j			4
	BASE	P0	P1	
0	S1	175	5	
7	X2	80,5	0,5	
0	S3	445	10	
	Zj	563,5	3,5	
		Cj - Zj	0,5	

Este valor = 0.5 se llama **tasa de sustitución** y nos indica que para fabricar una unidad de P1, debo dejar de fabricar (sacrificar) 0.5 unidades de P2. La misma interpretación se le debe dar al valor 5 (intersección entre S1 y P1) y al valor 10 (intersección entre S3 y P1).

Para interpretar el valor 5 tengo que tener en cuenta la restricción de mano de obra: $10x_1 + 10x_2$, es decir, para fabricar 1 una unidad de P1 necesito 10 HMO y lo mismo para P2, entonces si dejo de fabricar media unidad de P2: $10(0.5) = 5$ hs, voy a estar liberando 5 HMO, pero me faltan otras 5 HMO para fabricar una unidad de P1, voy a **"sacrificar"** entonces 5 hs del sobrante que tengo de HMO (175 en la tabla).

Ahora con respecto a las UMP, (valor 10 en la tabla (intersección entre S3 y P1)) voy a pensar de la misma manera, tengo que necesito (según las restricción de UMP: $15x_1 + 10x_2$) 15 UMP para producir una unidad de P1, entonces si dejo de fabricar media unidad de P2 me quedaría $10(0.5) = 5$ hs, ahora bien, me faltan otras 10 hs, entonces **sacrifico** 10 UMP del sobrante (en la tabla 445). Los valores 5 y 10 recién calculados coinciden con los de la tabla, de ahí la importancia de analizar bien la tabla simplex, ya que aporta mucha información.

C _i	C _j			4
	BASE	P0	P1	
0	S1	175	5	
7	X2	80,5	0,5	
0	S3	445	10	
	Zj	563,5	3,5	
		Cj - Zj	0,5	

Estos tres valores son nuestras **tasas de sustitución**, que me indican el "sacrificio" de la variable básica x_i (en este caso S_1, x_2 y S_3 , o sea las variables que están en la base, es decir, en las filas) para incrementar la variable no básica x_j (las que están en las columnas, en este caso P1) en **una unidad**. Esto es así siempre que las tasas sean **positivas**

Si la tasa de sustitución fuera **negativa**, indicaría la cantidad en que se incrementa el valor de la variable básica x_i .

C _i	C _j		
	BASE	P0	P1
0	S1	175	5
7	X2	80,5	0,5
0	S3	445	10
	Zj	563,5	3,5
	Cj - Zj		0,5

Sigamos analizando los demás valores de la tabla simplex:

Ahora, el valor de $Z_j = 3.5$ es lo que “dejo” de ganar por cambiar el plan de producción, en este caso es lo que dejó de ganar por producir una unidad de P1, y este valor sale de hacer $Z_1 = 0*(5) + 7*(0.5) + 0*(10) = 3.5$.

En conclusión, este valor de Z_j me está diciendo **en cuanto disminuye el valor de la función objetivo por cada unidad en que se incrementa el valor de x_j** (en este caso, la columna P1, es decir, cuánto disminuye Z por cada unidad en que incremento el Producto 1). Esto es **general para cualquier problema que estemos analizando**.

C _i	C _j		
	BASE	P0	P1
0	S1	175	5
7	X2	80,5	0,5
0	S3	445	10
	Zj	563,5	3,5
	Cj - Zj		0,5

Ahora vemos que \$4 es la contribución que me genera una unidad del producto 1, y 3.5 es lo que dejó de ganar por hacer los cambios necesarios para producir una unidad de P1, entonces su diferencia es $4 - 3.5 = 0.5$, este es el impacto neto, si este es > 0 me conviene entonces producir el P1, ya que la diferencia entre **lo que gano** y **lo que dejo de ganar** es positiva, incrementando entonces el valor de mi Z.

Este valor es el **Incremento marginal unitario del beneficio total**, que se calcula como el $c_j - z_j$, que **me indica cual va a ser el incremento neto unitario de la función objetivo Z**.

De acá sale el criterio de que variable entra a la base, ya que si es un caso de maximización, si $c_j - z_j > 0$ nos convenía introducir la variable en la base, en caso contrario, la función objetivo decrece y por ende no nos conviene introducirla en la base. Estamos acercándonos al SFB paso a paso.

Concluyendo, nos conviene producir P1 ya que Z se incrementa en \$0.5 por cada unidad

Ahora la pregunta es: ¿Cuántas unidades nos gustaría producir? TODAS las que podamos. Pero los recursos son limitados, entonces ¿Qué debo tener en cuenta para determinar esa cantidad máxima? No usar más recursos de los que tenemos, es decir, cuidar que ninguna variable asuma valor negativo.

¿Cómo calculo esa cantidad de unidades de P1 a fabricar?

Lo puedo calcular mediante las tasas de sustitución, tengo que saber cuántas unidades de P2 puedo sacrificar (Ya que por cada unidad de P1 sacrifico $\frac{1}{2}$ unidad de P2), ¿Hasta cuantas unidades de P2 puedo sacrificar? Hasta las unidades que estamos fabricando en este momento, este razonamiento se extiende a las demás variables de la base.

Por ejemplo, por cada unidad de P1, tengo que usar 5 hs de sobrante de HMO, hasta cuantas horas puedo usar? Evidentemente, hasta las que tengo como sobrante (como máximo 175)

Para saber la cantidad máxima de P1 a fabricar, la llamaremos θ , entonces:

Si por cada unidad de P1, tengo que sacrificar 0.5 unidades de P2

$0.5 * \theta \leq 80.5$ (puedo sacrificar hasta la cantidad que estoy produciendo actualmente)

Entonces, despejando $\theta \leq 161$

Aplico la misma lógica para las siguientes restricciones:

$5 * \theta \leq 175 \rightarrow \theta \leq 175/5 \leq 35$ (HMO)

$10 * \theta \leq 445 \rightarrow \theta \leq 445/10 \leq 44.5$ (UMP)

θ Será el valor que cumpla con **todas estas restricciones**, en este caso $\theta = 35$ (**valor máximo con el que puede entrar la nueva variable a la base**)

Ahora puedo calcular el nuevo plan de producción, o sea, la nueva solución:

$x_1 = \theta = 35$ unidades de P1

$x_2 = 80.5 - 0.5 * (35) = 63$ unidades de P2 (**lo que tengo - lo que sacrifico (unidades a producir * lo que sacrifico por cada unidad)**)

$S_1 = 175 - 5 * (35) = 0$ (HMO) $\rightarrow$ En el simplex este sería el valor que sale de la base

$S_2 = 0$

$S_3 = 445 - (35) * 10 = 95$ UMP sobrantes

Ahora falta ver en **cuánto asciende la contribución total de las utilidades (cj-zj)**

$Z^B = Z^A + 0.5 * (35) = 581$

El nuevo valor de Z va a ser igual al valor que ya teníamos más lo que se incrementa por producir las 35 unidades de P1.

La nueva solución obtenida al introducir x_1 a la base es

$X^B = [x_1 \ x_2 \ S_1 \ S_2 \ S_3] = [35 \ 63 \ 0 \ 0 \ 95]$; $Z^B = \$581$

Sin el simplex, no podemos saber si es la solución óptima o no, pero acá se ve **como pasar de una solución a otra utilizando los valores de la tabla.**

C_i	BASE	P0	P1	P2	P3	P4	P5
		λ_1					
		λ_2					
		λ_3					
	Z_j						
	$C_j - Z_j$						

λ_i ($i=1,m$): representa el valor actual de cada variable básica i en la solución actual.

	BASE	P0	P1	P2	P3	P4	P5
			λ_{11}	λ_{12}	λ_{13}	λ_{14}	λ_{15}
			λ_{21}	λ_{22}	λ_{23}	λ_{24}	λ_{25}
			λ_{31}	λ_{32}	λ_{33}	λ_{34}	λ_{35}
	Z_j						
	$C_j - Z_j$						

$\lambda_{ij} \ (i=1,m) \ (j=1,n)$

Tasas de sustitución: Indican el “sacrificio” o “disminución” de la variable básica x_i (var. que está en fila) para incrementar en una unidad la variable no básica x_j (variable que está en la columna).

Si la tasa de sustitución es **negativa** indica el “incremento” que se producirá en la variable básica x_i (fila) para incrementar una unidad la variable básica x_j (columna)

	BASE	P0	P1	P2	P3	P4	P5
	Z_j	Z_0					
	$C_j - Z_j$						

$Z_j = \sum_{i=1}^m C_i \lambda_{ij}$

Zj: Mide en **cuánto disminuye** el valor de la función objetivo por cada unidad en que se incrementa la variable no básica x_j

C_i	BASE	P0	P1	P2	P3	P4	P5
	Z_j						
	$C_j - Z_j$						

cj-zj: Representa el **incremento neto** del valor de Z por unidad del producto x_j .

● Indica el **valor de la nueva variable básica** en la siguiente solución. Se calcula como el mínimo de los cocientes de los λ_i/λ_{ij} . Para los $\lambda_{ij} > 0$, es decir, el VLD dividido por la columna de la variable que entra. Esto es así porque estamos buscando el máximo valor con el que puede entrar una variable en la base.

$x_i = \lambda_i - \theta \lambda_{ij}$ $x_j = \theta \quad \text{para } j \neq i, m$ $x_m = 0$	x_i: Cada una de las variables en la base. x_j: Variable que ingresa a la base x_m: Variable no básicas, al no formar parte de la base, son iguales a cero.
---	---

Unidad N°4: Dualidad y Análisis de sensibilidad

La dualidad y el análisis de sensibilidad son dos técnicas relacionadas con la PL. En la dualidad se ve la interpretación del concepto de precio sombra y en la dualidad se analiza cómo varía la solución del modelo (valor de Z como el de las variables de decisión) en función de dos conjuntos de parámetros del modelo: los **coeficientes de la función objetivo** y los **términos independientes de las restricciones**.

Precio Sombra

El precio sombra es un concepto fundamental en la optimización de recursos dentro del método símplex. Representa el valor que tiene un recurso para la empresa, más allá de su precio de mercado, y ayuda a tomar decisiones estratégicas sobre su uso o venta.

En la tabla símplex, la fila $z_j - c_j$ indica el impacto marginal que tiene liberar una unidad de un recurso. Si tomamos su **valor absoluto**, obtenemos el **precio sombra**, que **nos dice cuánto varía la función objetivo cuando se modifica en una unidad la disponibilidad de ese recurso, manteniendo todo lo demás constante**. Por ejemplo, si estamos evaluando horas de maquinaria disponibles y el precio sombra es 20, significa que cada hora adicional tendría un valor de 20 unidades en la producción. De igual manera, reducir una hora afectaría negativamente en la misma proporción.

Este concepto es clave porque nos permite evaluar si conviene seguir utilizando el recurso en producción o venderlo. Si el precio sombra es alto, la empresa debería priorizar su uso interno. Si es bajo, puede ser más rentable ofrecerlo a terceros.

Para que el cálculo sea correcto, es indispensable que la tabla símplex esté en el **punto óptimo**, de lo contrario, los precios sombra no reflejarán el verdadero impacto del recurso dentro del sistema productivo.

		HMO						HMa	uMP
Base	Cb	P0	P1	P2	P3	P4	P5	P6	
P4	0	200	-10	-5	0	1	-10	0	
P3	20	20	2	2	1	0	1	0	
P6	0	80	0	0	0	0	-1	1	
	z_j	400	40	40	20	0	20	0	
	$c_j - z_j$		-15	-10	0	0	-20	0	

La función Z disminuye en ese valor por dejar sin usar una HMa

En valor absoluto nos informa el valor de una hora adicional de horas máquina.

En valor absoluto indica en cuánto se incrementa el valor de Z por unidad adicional de b_i

Precio Sombra

Son los valores de las variables de un PL asociado a este problema y que se llama Problema Dual

Variables Duales (Precio Sombra)

Las variables duales en programación lineal están directamente relacionadas con el precio sombra, el cual indica cuánto afecta el incremento de un recurso en la función objetivo.

La fórmula representa la variación en la función objetivo Z cuando el valor del lado derecho (VLD) de una restricción i se incrementa en una unidad. En otras palabras, **expresa cuánto mejora la solución óptima si aumentamos la disponibilidad del recurso asociado a la restricción.**

$$y_i = \frac{\partial Z}{\partial b_i}$$

Incremento en la función Z

Incremento unitario del valor del lado derecho de la restricción i

La interpretación práctica de esta fórmula permite analizar si es conveniente aumentar la disponibilidad de ciertos recursos. Si el valor de y_i es alto, significa que aumentar VLD mejora significativamente la función objetivo, lo que sugiere que el recurso es valioso para la producción. En cambio, si y_i es bajo, el impacto del recurso es menor, y su disponibilidad adicional no afectaría demasiado el resultado final.

Dualidad

La dualidad en programación lineal establece que cada problema de optimización (primal) tiene un problema dual asociado, el cual se construye a partir del primero y trabaja en sentido opuesto. Si el problema primal es de maximización, el dual será de minimización, y viceversa.

La relación entre estos problemas es clave: **la solución óptima del problema primal también será la solución óptima del dual**, y **ambos compartirán el mismo valor de Z en el punto óptimo**. Es decir, el resultado final del problema dual refleja la misma información que el primal, pero desde una perspectiva diferente. Esto permite verificar soluciones y obtener interpretaciones adicionales sobre la asignación eficiente de recursos.

Una propiedad fundamental de la dualidad es que **el dual del dual es el primal**, lo que significa que si aplicamos el proceso de transformación nuevamente al problema dual, obtenemos el problema primal original.

¿Cómo pasar de uno al otro?

- ¿Cuántas variables tendrá el dual? → Tantas como restricciones tenga el primal
- ¿Cuántas restricciones tendrá el dual? → Tantas como variables tenga el primal
- ¿Cómo se relacionan las variables y restricciones entre primal y dual? → Las restricciones del primal se convierten en variables del dual, y las variables del primal en restricciones del dual.
- ¿Cuál será el sentido de optimización del objetivo en el dual? → Si el primal es de maximización, el dual será de minimización, y viceversa.
- ¿Qué coeficientes forman los valores del lado derecho en el dual? → Los coeficientes de la función objetivo del primal.

Dualidad Canónica

La dualidad canónica es un caso particular dentro de la dualidad en programación lineal. En este enfoque, los problemas tienen restricciones con signos específicos según su tipo de optimización:

- Problemas de minimización → Todas las restricciones tienen signo $\geq$.
- Problemas de maximización → Todas las restricciones tienen signo $\leq$.

Este esquema permite una mayor simplicidad en el análisis de dualidad, comparado con la dualidad mixta, donde las restricciones pueden tener distintos signos.

Mostramos un ejemplo

Los pasos básicos para formar el problema dual a partir del primal son:

- Si el primal es de maximización, el dual será de minimización, y viceversa.
- Las restricciones del primal se convierten en las variables del dual y los coeficientes de la función objetivo del primal pasan a ser los valores del lado derecho (LD) en el dual.
- Las variables del primal se convierten en las restricciones del dual, con coeficientes provenientes de la matriz de restricciones.

- Los signos de las restricciones cambian según la dualidad canónica:
 - En un problema de maximización, las restricciones del primal son $\leq$, por lo que las variables del dual serán $\geq$.
 - En un problema de minimización, las restricciones del primal son $\geq$, por lo que las variables del dual serán $\leq$.

Teorema Débil de Holguras Complementarias

El Teorema Débil de Complementariedad establece que **si una variable en un problema (primal o dual) es positiva, su variable relacionada en el otro problema es nula**. Sin embargo, **no se puede asegurar lo contrario**, es decir, que si una variable es nula, su contraparte en el otro problema sea positiva. Esta asimetría es lo que hace que el teorema sea "débil", ya que solo se cumple en una dirección.

Los casos que invalidan la afirmación inversa son:

- Variable básica con $VLD = 0 \rightarrow$ Aunque la variable es positiva, su impacto es nulo en la función objetivo.
- Variable no básica con $c_j - z_j = 0 \rightarrow$ Se generan múltiples soluciones óptimas, lo que rompe la exclusividad de la relación positiva-nula entre primal y dual.

			20	14	0	0	0
Base	C_b	P_b	P_1	P_2	P_3	P_4	P_5
P_5	0	0	0	0	1,5	-2	1
P_2	14	3	0	1	-0,25	1	0
P_1	20	2	1	0	0,25	-0,5	0
Z		82	20	14	1,5	4	0
			0	0	-1,5	-4	0
					Y_1	Y_2	Y_3

			54	45	0	0	0
Base	C_b	P_b	P_1	P_2	P_3	P_4	P_5
P_5	0	1,667	0	0	0,333	-0,4	1
P_1	54	5,556	1	0	-0,222	0,333	0
P_2	45	6,667	0	1	0,333	-0,4	0
Z		600	54	45	3	0	0
			0	0	-3	0	0
					Y_1	Y_2	Y_3

Dualidad Mixta

La dualidad mixta en programación lineal implica que las restricciones del problema primal pueden tener signos $\leq$, $\geq$ o $=$, lo que afecta la forma en que se construye el problema dual. La clave está en cómo el signo de la restricción del primal determina las condiciones de las variables duales.

Tabla para pasar de uno a otro:

	Problema de Máximo			Problema de Mínimo		
Restricción	Canónica	$\leq$	$\rightarrow$	≥ 0	No Negativa	Variable
	No Canónica	$\geq$	$\rightarrow$	≤ 0	No Positiva	
	Igualdad	$=$	$\rightarrow$	n/r	No Restringida	
Variable	No Negativa	≥ 0	$\rightarrow$	$\geq$	Canónica	Restricción
	No Positiva	≤ 0	$\rightarrow$	$\leq$	No Canónica	
	No Restringida	n/r	$\rightarrow$	$=$	Igualdad	

Ejemplo:

$$\begin{aligned}
 &\text{Max } 24x_1 + 36x_2 + 18x_3 + 20x_4 \\
 &\text{sujeto a:} \\
 &10x_1 + 10x_2 + 12x_3 + 8x_4 \leq 180 \\
 &x_1 + 2x_2 + 3x_3 + x_4 \geq 60 \\
 &6x_1 + 2x_2 - x_3 + 8x_4 = 100 \\
 &x_1 \geq 0; x_2 \leq 0; x_3 \text{ s.r.}; x_4 \geq 0
 \end{aligned}$$

$$\begin{aligned}
 &\text{Min } 180y_1 + 60y_2 + 100y_3 \\
 &\text{sujeto a:} \\
 &10y_1 + y_2 + 6y_3 \geq 24 \\
 &10y_1 + 2y_2 + 2y_3 \leq 36 \\
 &12y_1 + 3y_2 - 1y_3 = 18 \\
 &8y_1 + y_2 + 8y_3 \geq 20 \\
 &y_1 \geq 0; y_2 \leq 0; y_3 \text{ s.r.}
 \end{aligned}$$

Una recomendación acá, a la hora de plantear la no negatividad de las variables duales y_i , me fijo en la restricción relacionada con esa variable dual, es decir, para ver el signo de y_1 me fijo el signo de la restricción relacionada R_1 , como ésta es una restricción canónica (para un problema de máximo, asegúrense de ver siempre eso, si la restricción es canónica según de qué tipo de problema se trate, max o min), en el dual y_1 va a ser no negativa.

Análisis de Sensibilidad

El análisis de sensibilidad en programación lineal **se utiliza para evaluar cómo afectan los cambios en los parámetros del modelo a la solución óptima**. Dado que los modelos son deterministas y estáticos, no contemplan variaciones en los datos, por lo que es necesario estudiar qué sucede si algunos valores cambian.

El objetivo principal es **determinar intervalos de variación en los parámetros del modelo sin que sea necesario reformular toda la estructura matemática**. Por ejemplo, si se consigue más disponibilidad de horas de maquinaria, el análisis de sensibilidad permite verificar si el punto óptimo sigue siendo el mismo o si es necesario realizar ajustes en las decisiones tomadas.

Sobre qué parámetros se realiza?

Coefficientes de la Función Objetivo (c_i):

- Variable No Básica: Analiza cómo afecta la solución si el coeficiente cambia, aunque la variable no está en la base.
- Variable Básica: Se revisa el impacto directo sobre la solución óptima cuando el coeficiente de una variable incluida en la base se modifica.

Valores del Lado Derecho (b_i):

- Restricción No Limitante: Si el valor cambia, no afecta la solución porque la restricción no influye en la frontera óptima.
- Restricción Limitante: Se estudia el impacto en el punto óptimo cuando el parámetro se modifica, ya que la restricción sí está determinando el resultado.

Efecto en el gráfico

Cuando se modifica un coeficiente de la función objetivo, lo que cambia es la pendiente de la recta que representa la función objetivo. Esto puede alterar cuál es el punto óptimo, ya que la nueva inclinación de la recta puede hacer que otra intersección con la región factible sea más favorable.


$$z = c_1 x_1 + c_2 x_2 \quad x_2 = \frac{z}{c_2} - \frac{c_1}{c_2} x_1$$

Por otro lado, cuando se modifica un valor del lado derecho de una restricción, lo que cambia es su ordenada al origen en el gráfico. En términos prácticos, esto significa que la restricción puede moverse, expandiendo o contrayendo la región factible. Si el valor del lado derecho aumenta, la restricción se desplaza, aumentando el espacio de posibles soluciones. Si disminuye, la restricción se vuelve más estricta, reduciendo el conjunto de soluciones posibles.

$$a_{11} x_1 + a_{12} x_2 \leq b_1 \quad x_2 = \frac{b_1}{a_{12}} - \frac{a_{11}}{a_{12}} x_1$$



Ahora bien, qué sucede si estos incrementos en exactamente el intervalo de sensibilidad?

- Si el coeficiente c_j se incrementa (o disminuye) en exactamente el incremento (o disminución) del intervalo de sensibilidad se van a obtener múltiples soluciones.
- Si el coeficiente b_i se incrementa (o disminuye) en exactamente el incremento (o disminución) del intervalo de sensibilidad va a cambiar el punto de optimizado y se va a transformar en una solución degenerada.



Efectos de los Cambios

El efecto de los cambios en los coeficientes de un modelo de programación lineal puede alterar diferentes elementos clave del problema. Dependiendo de qué parámetro se modifique, el impacto puede reflejarse en la base óptima, la solución óptima o directamente en el valor de Z.



Cálculo de los intervalos de los coeficientes para c_i

Para los c_i de las Variables No Básicas ($c_i = 0$)

El intervalo de los coeficientes para variables no básicas se determina analizando la diferencia $c_j - z_j$, asegurando que la base no cambie.

- En maximización, $c_j - z_j \leq 0$ para mantener la optimalidad.
- En minimización, $c_j - z_j \geq 0$ para conservar la solución óptima.

Si los coeficientes de una variable no básica cambian demasiado y $c_j - z_j$ deja de cumplir la condición, la base debe modificarse, lo que puede afectar la estabilidad del modelo.

Para los c_i de las Variables Básicas ($c_j - z_j = 0$)

Se determina evaluando el límite máximo de cambio permitido antes de que sea necesario recalcular la fila $c_j - z_j$ para las variables no básicas. Cada variable no básica genera una restricción que establece los límites de variación del coeficiente. A partir de este sistema de restricciones, se despejan los valores de incremento y disminución.

Esto parte de la idea de que, por ejemplo, en un problema de maximización, si el coeficiente c_i disminuye demasiado, su contribución se vuelve menos rentable que otro producto, lo que puede requerir un cambio en la base óptima.

Ejemplo:

c_1 : Coeficiente de variable no básica, puede incrementar máximo hasta 15 unidades, sin tener que cambiar la base (agregarla a la base), pero la misma puede decrementar infinitamente sin afectar a la base actual (por ser maximización).

c_3 : Coeficiente de variable básica, se resuelve el sistema de ecuaciones, y se determina que sólo puede decrementar en 5 unidades antes de tener que cambiar la base, pero puede incrementar infinitamente (por ser maximización), tener en cuenta que se hace **una ecuación por cada variable no básica**.

Cálculo del intervalo para c_j

	Incremento	Disminución
c_1	15	∞
c_3	∞	5

			25	30	20	0	0	0
Base	Cb	P0	P1	P2	P3	P4	P5	P6
S_1	0	200	-10	-5	0	1	-10	0
x_3	20	20	2	2	1	0	1	0
S_3	0	80	0	0	0	0	-1	1
Z	400	40	40	20	0	20	0	0
$c_j - z_j$			-15	-10	0	0	-20	0

$$(c_j - z_j)^* = (c_j - z_j) - \lambda_{3j} \Delta c_3 \leq 0$$

$$(c_1 - z_1)^* = -15 - 2\Delta c_3 \leq 0$$

$$-2\Delta c_3 \leq 15$$

$$\Delta c_3 \geq -7,5$$

$$(c_2 - z_2)^* = -10 - 2\Delta c_3 \leq 0$$


$$\Delta c_3 \geq \frac{10}{-2}$$

$$\Delta c_3 \geq -5$$

$$(c_5 - z_5)^* = -20 - \Delta c_3 \leq 0$$

$$\Delta c_3 \geq -\frac{20}{1}$$

$$\Delta c_3 \geq -20$$



Cálculo de los intervalos de los VLD (b_i)

Para determinar el intervalo de sensibilidad, primero se debe analizar si la restricción es limitante o no limitante.

- Si la restricción es **no limitante** (en la tabla se ve como una variable de holgura o excedente mayor a 0), se evalúa el valor de la variable de holgura para definir el intervalo de sensibilidad.
- Si la restricción es **limitante** (en la tabla se ve como una variable de holgura o excedente igual a 0), se utiliza el vector solución junto con la columna de la variable de holgura, excedente o artificial, dependiendo del caso, y considerando la condición de factibilidad.

Las tasas de sustitución (λ_{ij}) indican cómo varía la holgura del b_i analizado:

- En restricciones de $\leq$, λ_{ij} representa la sustitución de la holgura.
- En restricciones de $\geq$ o $=$, λ_{ij} corresponde a la sustitución de la variable artificial.

Ejemplo:

- b_1 : Restricción no limitante, puede incrementar todo lo que quiera que no genera ninguna cambio (simplemente va a sobrar más), pero no puede disminuir más de 200 (que es lo que sobró, porque si no, ya no se puede fabricar la solución actual). Lo mismo para b_3 , pero no puede disminuir más de 80.
- b_2 : Restricción limitante, arma el sistema de inequación, y con eso obtiene los valores en el VLD puede incrementar y decrementar sin alterar la base.

Cálculo del intervalo para b_i


	Incremento	Disminución
b_1	∞	200
b_2	20	20
b_3	∞	80

Base	Cb	P0	25	30	20	0	0	0
			P1	P2	P3	P4	P5	P6
S_1	0	200	-10	-5	0	1	-10	0
x_3	20	20	2	2	1	0	1	0
S_3	0	80	0	0	0	0	-1	1
Z		400	40	40	20	0	20	0
$C_j - Z_j$			-15	-10	0	0	-20	0

$$\begin{bmatrix} 200 \\ 20 \\ 80 \end{bmatrix} + \Delta b_2 \begin{bmatrix} -10 \\ 1 \\ -1 \end{bmatrix} \geq 0$$

$$\begin{aligned} 200 - 10\Delta b_2 &\geq 0 & -10\Delta b_2 &\geq -200 & \Delta b_2 &\leq 20 \\ 20 + \Delta b_2 &\geq 0 & & & \Delta b_2 &\geq -20 \\ 80 - \Delta b_2 &\geq 0 & -\Delta b_2 &\geq 80 & \Delta b_2 &\leq 80 \end{aligned}$$

Tabla resumen



Nueva Variable

Para evaluar si conviene fabricar un nuevo producto, se debe realizar un análisis de sensibilidad, esto implica determinar cómo afectará la introducción de la nueva variable a la solución óptima. Para ello es necesario tener todos los datos necesarios (contribución, uso recursos y precios sombra de esos recursos).

Requerimientos del P4				
P4 → 14 HMO				
P4 → 1 HMa				
P4 → 2 unidades de MP				
Contri. a la utilidades \$28				
		Precio Sombra	Costo de oportunidad	
HMO	14	0	0	\$ 0,00
Hs. Máquina	1	20	20	\$ 20,00
U. Materia Prima	2	0	0	\$ 0,00
Contribución (\$/unid)	\$ 28,00		\$ 20,00	\$ 8,00

Conviene producir el P4

Ejemplo de Informe de solución con Lindo

Solución óptima y dual			Análisis de Sensibilidad		
OBJECTIVE FUNCTION VALUE			RANGES IN WHICH THE BASIS IS UNCHANGED:		
1)	2667.500	→ Z_0	OBJ COEFFICIENT RANGES		
VARIABLE	VALUE	REDUCED COST	VARIABLE	CURRENT COEF	ALLOWABLE INCREASE
G1	57.500000	0.000000	G1	13.000000	19.000000
G2	85.000000	0.000000	G2	16.000000	10.000000
G3	40.000000	0.000000	G3	14.000000	1.055556
valores de X_i en SO			coef. de X_i (C_i) ΔC_i		
ROW	SLACK OR SURPLUS	DUAL PRICES	ROW	CURRENT RHS	ALLOWABLE INCREASE
H ACANAL	55.000000	0.000000	H ACANAL	950.000000	INFINITY
H PLANO	0.000000	1.111111	H PLANO	800.000000	165.000000
H REDON	0.000000	1.583333	H REDON	1150.000000	110.000000
PRO MIN	0.000000	-1.055556	PRO MIN	40.000000	41.250000
holgura valores de S_i			RIGHTHAND SIDE RANGES		
			VLD (b_i) Δb_i		

OBJECTIVE FUNCTION VALUE			
1)	105000.0		
VARIABLE	VALUE	REDUCED COST	
X1	0.000000	0.500000	Disminución que se produce en z por cada unidad en que se incrementa la variable
X2	500.000000	0.000000	
X3	2500.000000	0.000000	
X4	0.000000	35.000000	
ROW	SLACK OR SURPLUS	DUAL PRICES	
2)	0.000000	1.500000	Mejora que se produce en z por cada unidad en que se incrementa el lado derecho de la restricción. Tiene validez dentro del intervalo de sensibilidad.
3)	17000.000000	0.000000	
4)	0.000000	9.000000	
RANGES IN WHICH THE BASIS IS UNCHANGED:			
OBJ COEFFICIENT RANGES			
VARIABLE	CURRENT COEF	ALLOWABLE INCREASE	ALLOWABLE DECREASE
X1	40.000000	0.500000	INFINITY
X2	60.000000	30.000000	0.769231
X3	30.000000	90.000000	9.999998
X4	10.000000	35.000000	INFINITY
RIGHTHAND SIDE RANGES			
ROW	CURRENT RHS	ALLOWABLE INCREASE	ALLOWABLE DECREASE
2	22000.0000	10000.0000	16666.666016
3	28000.0000	INFINITY	17000.000000
4	8000.0000	25000.0000	2500.000000

Variable no básica
Si la variación del coeficiente de x_1 se produce dentro de este rango, no se producen cambios en los valores de las variables, ni en el valor de z

Variable básica
Si la variación del coeficiente de x_2 se produce dentro de este rango, no se producen cambios en los valores de las variables, sólo varía el valor de z

Restricción no limitante
Si la variación del RHS se produce dentro de este rango, sólo se modifica el valor de la holgura

Restricción limitante
Si la variación del RHS se produce dentro de este rango, no cambia la base, pero varían los valores de las variables básicas y el valor de z

Unidad N°5: Programación no lineal

Un problema de PNL surge del incumplimiento de alguno de estos dos supuestos de PL (ver los supuestos de la PL más arriba para ver los ejemplos):

- **Aditividad:** No se cumple cuando las contribuciones de dos o más variables al objetivo o a las restricciones no son independientes entre sí, es decir, no hay productos cruzados entre variables (como $\max Z = 3xy$ o x^2). Un ejemplo sería cuando se unen sustancias químicas, el volumen resultante no necesariamente es la suma de los volúmenes de las sustancias.
- **Proporcionalidad:** Este supuesto no se cumple cuando las contribuciones al objetivo o a las restricciones no son proporcionales a los valores de las variables, por ejemplo, cuando el ingreso obtenido no es proporcional a la cantidad de unidades vendidas, como cuando se aplican descuentos por volumen, como vender 100 unidades a \$100 cada una y 200 unidades a \$80 cada una.

Ahora, hay algo muy importante acá, que es la posibilidad de lograr la **optimización de estos modelos es mucho más difícil que en los modelos lineales**, y que **los algoritmos desarrollados para su resolución son menos eficientes**. **No se puede asegurar que un algoritmo de resolución de PNL logrará siempre encontrar la solución óptima para cualquier problema.**

Sin embargo, en muchos casos, mediante PL se pueden obtener buenas aproximaciones a los modelos no lineales.

De manera general un problema de PNL consiste en encontrar los valores de n variables $X = (x_1, x_2, \dots, x_n)$, tal que:



$$\begin{array}{ll} \text{Max } f(x) \\ \text{s.a.} \\ g_i(x) \leq b_i \quad i = 1, 2, \dots, m \\ x \geq 0 \end{array}$$

Donde $f(x)$ y $g_i(x)$ son funciones de n variables de decisión y además $f(x)$ y/o $g_i(x)$ son no lineales.

Características generales de la PNL


Un PNL con dos variables de decisión, al igual que un PL, puede representarse gráficamente, esto es útil para mostrar las características de las soluciones óptimas:

- La región factible no es necesariamente un poliedro como el caso de la PL y la solución óptima puede **no** encontrarse en un vértice. La restricción no lineal forma parte de la frontera del conjunto de soluciones posibles y sólo existe una restricción limitante. **La región factible es un conjunto convexo pero NO un poliedro.**
- En el siguiente gráfico, todas las restricciones son lineales y por ende el conjunto de soluciones factibles **es un poliedro convexo**. Sin embargo, la función objetivo **no es lineal**, y como vemos, el **óptimo no se presenta en un vértice**. Efectivamente, algunas soluciones óptimas para algunas funciones objetivo no lineales pueden ni siquiera estar en la frontera de la región factible, pudiendo ser, por ejemplo, un punto interior de dicha región.



Este último punto tiene una consecuencia muy importante, es que para la resolución de este tipo de problemas se tienen que tener en cuenta **todas las soluciones de la región factible**, y no solo aquellas que están en los vértices.



- Un inconveniente que surge en los PNL es la aparición de **óptimos locales** y **óptimos globales**. En PL siempre un óptimo local es también un óptimo global, cosa que no ocurre en PNL. En el punto “óptimo global” el valor de la función objetivo es mejor que en todos los demás puntos factibles. Para garantizar que un óptimo local también sea global, deben satisfacerse ciertas condiciones de concavidad y convexidad.



Tipos de programas no lineales

Como un PNL se puede presentar de distintas formas, no existe un algoritmo que resuelva todos estos tipos especiales de problemas, se desarrollaron entonces algoritmos para los tipos más comunes de PNL, por ello es importante conocer cuáles son estos tipos y diferenciar los problemas que podremos optimizar de los que podemos encontrar el óptimo.

- Optimización no restringida: Si un problema de PNL no tiene restricciones, el hecho de que la función objetivo sea cóncava nos garantiza que un máximo local es un máximo global, análogamente una función objetivo convexa garantiza que un mínimo local también es un mínimo global. Si la función es **cóncava** el segmento de recta que conecta dos puntos cualesquiera de la gráfica de la función nunca pertenece al espacio ubicado por arriba de la gráfica. En cambio, si la función es **convexa** el segmento de recta que conecta dos puntos cualesquiera de la gráfica de la función nunca pertenece al espacio ubicado por debajo de la gráfica.



- Optimización restringida: Si existen restricciones, para garantizar que un óptimo local sea también global, se necesita como condición adicional que el conjunto de restricciones sea convexo. En general, la región de soluciones factibles de un PNL es convexa si la función de restricción $g(x)$ asociada con cada restricción del tipo $\leq$ es convexa y la función de restricción $g(x)$ asociada con cada restricción del tipo $\geq$ es cóncava. (mirar los 2 gráficos de arriba)
- Programación convexa: Comprende a los problemas de PNL que tienen función objetivo cóncava en problema de maximización, o convexa para problemas de minimización y una región factible que es un conjunto convexo. Dentro de la programación convexa encontramos a:

- Los *Programas linealmente restringidos*, cuya característica principal es que **cualquier óptimo local, es también un óptimo global**. Estos resultan los PNL más sencillos de resolver. Y como casos especiales tenemos.
 - *Programación cuadrática*: La única diferencia entre los problemas de Programación Cuadrática (PC) y los de PL es que la función objetivo incluye el cuadrado de una variable o el producto de dos variables. La PC es importante ya que este tipo de formulaciones surgen naturalmente en gran cantidad de aplicaciones, como carteras de inversión.
 - *Programación separable*: Se agrega el supuesto adicional de que todas las funciones $f(x)$ y $g_i(x)$ son separables. Una función es separable cuando cada término sólo incluye una variable, por lo que puede expresarse como una suma de funciones de distintas variables. Este tipo de problemas satisface el supuesto de aditividad pero no el de proporcionalidad.
- Por ejemplo la función

$$f(x_1, x_2) = -10x_1^2 + 20x_2^2 + 50x_1 - 25x_2$$

Puede expresarse como

$$f(x_1, x_2) = f(x_1) + f(x_2)$$

Dónde

$$f(x_1) = -10x_1^2 + 50x_1$$
$$f(x_2) = 20x_2^2 - 25x_2$$
- Programación no convexa: Aquí se incluyen todos los problemas generales no lineales, en los cuales NO se cumplen los supuestos de la programación convexa. En estos casos aun cuando se tenga éxito en encontrar un óptimo local, no hay garantía de que sea también un óptimo global. Los algoritmos para resolver programas no lineales generales se basan en cálculo avanzado y utilizan la tasa de cambio de la función objetivo mediante el vector gradiente, compuesto por las derivadas parciales de las variables. A partir de un punto inicial, el método avanza en la dirección de mayor aumento (en maximización) hasta alcanzar un óptimo local, definido como el punto donde las derivadas parciales se aproximan a cero. Si se desea encontrar otros óptimos locales, el proceso se reinicia desde diferentes puntos iniciales.

Precio sombra vs. Multiplicador de Lagrange (pregunta de examen)

El Precio Sombra y el Multiplicador de Lagrange son conceptualmente iguales, ya que ambos indican cuánto se incrementa la función objetivo Z ante un aumento en un recurso (VLD), pero difieren en el intervalo de validez: **el Precio Sombra se aplica dentro de un rango en el que la solución sigue siendo óptima**, mientras que **el Multiplicador de Lagrange se refiere a un incremento infinitesimal (variaciones pequeñas) del recurso**. En otras palabras, aunque representan lo mismo desde el punto de vista económico, se usan en contextos distintos; son como dos mellizos: iguales en esencia, pero pueden “vestirse distinto” según la situación.

Ejemplo: Supongamos un problema de programación lineal donde queremos maximizar ganancias sujetas a una restricción de horas de máquina disponibles (por ejemplo, 100 horas).

- El **Precio Sombra** te dice que por cada hora adicional que consigas (dentro del rango válido), tu ganancia total aumentará, por ejemplo, \$50. Pero este valor sólo es válido mientras no cambie la base óptima (es decir, dentro de cierto rango de aumento, como hasta 20 horas más), es válido dentro de un rango finito.
- El **Multiplicador de Lagrange**, en cambio, te dice cuánto se incrementa la función objetivo si el recurso se incrementará en una cantidad infinitesimal (cercana a cero, un valor M extremadamente pequeño), como por ejemplo 0.000001 horas máquina. Este valor no depende del rango de validez porque es una derivada, pero no te garantiza que la solución sea óptima si realmente agregás una hora completa, **ya que no considera cambios en la estructura del problema**, es válido sólo en un punto.

Unidad N°6: Modelos de Redes de Programación Lineal

Conceptos Básicos

Grafo o Red

Par ordenado del tipo (X, U) , donde X es un conjunto finito de elementos llamados *vértices* o *nodos* de la red, y U representa una relación binaria entre los nodos del conjunto X , es decir:

$$U \subseteq X^2 = \{(x_i, x_j) / x_i \in X \wedge x_j \in X\}$$

Estas relaciones son arcos de la red. Por ejemplo:

$$X = \{x_1, x_2, x_3, x_4, x_5, x_6, x_7\} \quad (1)$$

$$U = \{(x_1, x_3), (x_1, x_5), (x_1, x_7), (x_2, x_4), (x_3, x_1), (x_3, x_2), (x_4, x_3), (x_5, x_1), (x_7, x_4), (x_7, x_6)\}$$

Representación Gráfica de una Red

Lo hacemos asociando a cada elemento de X , un punto en el plano que representará un nodo o vértice de la red y cada relación de U estará graficado como una flecha o arco que va desde el vértice inicial al vértice final. La gráfica de la red definida en (1), sería la siguiente.




Gráfico 1

Camino por los Arcos

Llamamos *camino* a la sucesión o secuencia de arcos de un grafo, dado que, para cualquier arco del camino su vértice final debe coincidir con el vértice inicial del siguiente. Un camino de la red (1) sería:

$$\mu = \langle (x_3, x_2), (x_2, x_4), (x_4, x_3), (x_3, x_1) \rangle \quad (2)$$

Llamamos *longitud* de un camino al número de arcos que lo forman, así para (2) sería longitud 4 ($l(u) = 4$).

Cuando el vértice inicial y final de un camino coinciden, diremos que forma un *circuito*.

Un *subcamino*, de un camino dado, es una secuencia cualquiera de arcos consecutivos del mismo. Por ejemplo, de (2), un subcamino sería:

$$\mu^0 = \langle (x_2, x_4), (x_4, x_3), (x_3, x_1) \rangle$$

Valor de un Camino por los Arcos

Si asociamos un número (que puede representar costo, tiempo, distancia, etc) a cada arco de un grafo, a este número lo llamamos *valor de un arco*. Se simboliza como:

$$v(x_i, x_j) \text{ o } v_{i,j}.$$

El *valor de un camino* será entonces la suma de los valores de todos los arcos que lo componen. Para el caso de (2), tendríamos:

$$v(\mu) = v_{3,2} + v_{2,4} + v_{4,3} + v_{3,1}$$

O si $\mu = \langle \mu_1, \mu_2, \mu_3 \rangle$, siendo μ_1, μ_2 y μ_3 tres subcaminos resultantes de una partición del camino μ , tendremos:

$$v(\mu) = v(\mu_1) + v(\mu_2) + v(\mu_3)$$

Camino por los Vértices

Cuando definimos un camino como una secuencia de arcos, queda automáticamente definida una única secuencia de vértices: la de los vértices por los cuales "pasa" ese camino. Por lo tanto, dada una red $G=(X,U)$, podemos también dar el concepto de camino como una secuencia o sucesión de vértices.

La *longitud* de un camino definido como secuencia de vértices es igual al número de vértices que lo integran, menos uno. Cuando consideramos caminos como secuencias de vértices, también podemos particionar el mismo en subsecuencias o subcaminos.

Valor de un Camino por los Vértices

Si asociamos un número a cada vértice, lo llamaremos *valor del vértice* y se lo simboliza por

$$v_i = v(x_i).$$

Entonces, el valor de un camino por los vértices es la suma de los valores de todos los vértices que forman la secuencia correspondiente. Del camino (2), tendríamos:

$$v(\mu) = v_3 + v_2 + v_4 + v_3 + v_1$$

Teorema de la Optimidad

El teorema se enuncia como: "*Todo subcamino de un camino de valuación óptima, es también de valuación óptima, comparado con todos los otros caminos que unen sus mismos vértices extremos*".

Caminos de Valor Mínimo

Algoritmo de Dijkstra


Lo usamos para identificar los caminos de valor mínimo que unen un vértice origen con cada uno de los nodos del grafo. Consiste en establecer una etiqueta a cada nodo de la red, la que luego de sucesivas actualizaciones, contendrá el valor del camino de valor mínimo que une el nodo inicio del grafo con el nodo considerado y el vértice precedente en dicho camino.

Para eso, procedemos de la siguiente forma:

1. Considere todos los vértices que estén conectados con el origen por un camino de longitud 1. A cada uno de ellos se le colocará una etiqueta de la siguiente forma: $[j, d]$.
 d mide la distancia desde el origen al nodo considerado (i). j es el nodo precedente, el origen en primera instancia. Estas etiquetas son temporales.
2. De todos los nodos con etiqueta temporal, se elige uno cuyo d sea la menor y se lo etiqueta como permanente. Los empates se rompen arbitrariamente. Cuando todos los nodos son permanentes se pasa al paso 4.
3. Si i es el último etiquetado permanente, considere todos los vértices que estén conectados directamente con éste a través de un camino de longitud 1, siempre y cuando no estén etiquetados como permanentes. Para cada uno de ellos calcular la suma de su d a i más la d de la etiqueta de i .
 Si el vértice no está etiquetado darle una etiqueta temporal. Si ya tiene etiqueta temporal, cambiarla sólo si la distancia recién calculada es menor que la componente de distancia de la etiqueta actual. Si la distancia recién calculada es igual a la que tiene la etiqueta anterior, conservar ambas. Regresar al Paso 2.
4. Las etiqueta permanentes indican la menor distancia desde el origen a cada nodo de la red. También indican el nodo precedente en la ruta de valor mínimo hacia cada vértice.

Ejemplo de Aplicación de Dijkstra

Supongamos que tenemos esta red:



Identificamos todos los nodos que estén conectados con el origen (nodo 1) por un camino de longitud 1. En este caso son los nodos 2 y 3. A ellos le ponemos una etiqueta temporal y luego elegimos el de menor distancia y lo etiquetamos como permanente:




Gráfico 3

Ahora, del último nodo permanente (3), identificamos todos los vértices conectados a él por un camino de longitud 1 y que no estén etiquetados como permanentes. Calculamos la distancia de 3 a dicho vértice y le asignamos una etiqueta temporal. En el caso de que el nodo ya tenga etiqueta, ésta se cambiará sólo en el caso de que la distancia sea menor, si la distancia es igual se dejan ambas etiquetas:




Gráfico 4

Luego, de todos los vértices que tienen etiqueta temporal, elegimos el que tenga menor componente de distancia y lo marcamos como permanente, en este caso, el nodo 2:




Gráfico 5

Y así vamos repitiendo los pasos anteriores. Nos queda como permanente el nodo 4:




Gráfico 6

Luego:




Gráfico 7

Cuando ya no nos quedan nodos por investigar, procedemos a identificar el camino de valor mínimo a través del análisis de las etiquetas de cada nodo. Por ejemplo, si queremos el camino de valor mínimo desde el nodo origen 1 hasta el nodo 6, quedaría:




Gráfico 8

Para este grafo, el camino de valor mínimo por los arcos es:

$$\mu = \{(1, 3), (3, 5), (5, 6)\} \text{ y el valor del camino es } v(\mu) = 8$$

Árbol de Expansión Mínima

Un *árbol de expansión* es un grafo que tiene n nodos, conexo y que no tiene ciclos no dirigidos. Tiene exactamente $n-1$ arcos y éste es el número mínimo de arcos para tener un grafo conexo y el máximo número posible para que no haya ciclos no dirigidos.

Por ejemplo:




Gráfico 11

En el problema de *árbol de expansión mínima*, los grafos tienen valores en las ligaduras de los nodos que representan distancia, costo, tiempo, etc. El objetivo es seleccionar un conjunto de aristas de valor mínimo entre todo el conjunto de ligaduras que satisfacen la propiedad de proporcionar un camino o trayectoria entre cada par de nodos. Por lo tanto, el problema es encontrar el árbol de expansión con el valor total mínimo de sus aristas.

Algoritmo para encontrar el Árbol de Expansión Mínima:

1. Seleccionar de manera arbitraria cualquier nodo como inicio, de todos los nodos conectados al inicio a través de una arista, seleccionar el de menor valor. Quedan ahora

dos conjuntos, el de nodos Conectados (C), cuyas aristas estarán en el árbol de expansión mínima y el conjunto de nodos No Conectados (NC).

2. Identificar del conjunto NC el nodo que se conecte con algún nodo del conjunto C a través de la arista de menor valor y se lo conecta con este. Los empates se resuelven arbitrariamente.
3. Se procede de esta manera hasta que todos los nodos estén conectados. En cada paso el algoritmo elige la arista de menor valor que se puede usar para expandir C.

Ejemplo de Aplicación de Árbol de Expansión Mínima

Queremos encontrar el árbol de expansión mínima del siguiente grafo:




Gráfico 12

Elegimos al nodo B como nodo inicial, luego elegimo A para conectarlo con B:




Gráfico 13

El nodo conectado a A o B, con arista de menor valor es D (con respecto a B), entonces lo conectamos a B:




Gráfico 14

El nodo conectado a A, B o D con arista de menor valor es C (con respecto a D), lo conectamos a D:




Gráfico 15

El nodo conectado a A, B, D o C con arista de menor valor es F (con respecto a D), lo conectamos a D:




Gráfico 16

El nodo conectado a A, B, D, C o F con arista de menor valor es E (con respecto a F), lo conectamos a F:




Gráfico 17

El único nodo no conectado es G con la arista de menor valor respecto a E. Lo conectamos a E:




Gráfico 18

Y nos queda el siguiente árbol de expansión mínima:




Gráfico N° 19


Con un valor de 13.

Problema de Flujo Máximo

Se utiliza para aquellos casos en los que se desea determinar la circulación máxima de algún tipo de bien a través de una red que posee un único nodo de entrada y un único nodo de salida, y cada arco tiene una restricción de flujo.

El requerimiento que se debe dar en los nodos, excepto en el de inicio y destino, es que debe existir el equilibrio: Flujo que sale = Flujo que entra.

En base a las restricciones de equilibrio, las de flujo y las de no negatividad, se arma un problema lineal de maximización de la siguiente manera:



Unidad 7: Pronósticos

Son métodos de predicción de valores a futuro, estos pueden ser:

- **Cualitativos.** ← Hacen uso del juicio de quien pronostica. Las técnicas cualitativas se usan cuando no se tiene disponibilidad de información histórica o los datos son escasos.
- **Cuantitativos.**
 - **Pronósticos de Series Temporales o de Extrapolación.** ← Se utilizan para pronosticar a partir de valores anteriores observados a intervalos regulares de tiempo. Se asume que las tendencias y los patrones de comportamiento continuarán en el futuro.
 - **Predicción Causal.** ← Se basan en el supuesto de que la variables que tratamos de pronosticar muestra una relación causa-efecto con una o más variables, es decir, pronosticamos los valores futuros de una variable dependiente.

Es mejor pensar en los métodos de pronóstico como herramientas que pueden aplicarse simultáneamente. El método seleccionado debería producir un pronóstico que sea correcto, oportuno y comprensible para la gerencia.

Etapas del pronóstico

1. **Formulación del problema y recopilación de datos:** El problema determina los datos apropiados. Si pronosticamos cuantitativamente, los datos pertinentes deben estar disponibles e igualmente espaciados.
2. **Manipulación y limpieza de datos:** Es necesario porque es posible demasiados datos o muy pocos, o que algunos datos no sean pertinentes o falten valores que se deban estimar. Los datos deben estar de forma adecuada para pronosticar.
3. **Construcción y evaluación del modelo:** Ajustar los datos recolectados a un modelo de pronóstico que sea adecuado para minimizar errores. Cuanto más sencillo sea el modelo, mejor será el proceso de pronóstico.
4. **Implementación del modelo:** Generación del modelo real. Los datos de periodos históricos más recientes se mantienen como respaldo y más tarde se usan para verificar la exactitud del modelo.
5. **Evaluación del pronóstico:** Comparación de los valores del pronóstico con los reales. Se puede modificar el modelo para mejorar el pronóstico.

Métodos Cuantitativos de Pronóstico

Series de Tiempo

Los datos deben ser fidedignos, precisos, consistentes, oportunos y relevantes; tienen que ser representativos de las circunstancias para las cuales se están usando.

Una *serie de tiempo* es un conjunto de observaciones de una variable medida durante incrementos de tiempo fijos y sucesivos.

El objetivo de los métodos de serie de tiempo es descubrir un patrón en los datos históricos y luego extrapolarlo hacia el futuro

Componentes de una serie de tiempo:

1. **Componente de tendencia:** Es el cambio gradual de la serie de tiempo. Este cambio es el resultado de factores a largo plazo, como cambios en la población, características demográficas de la población, tecnología y preferencias de consumo. Puede ser creciente o decreciente, lineal o no lineal. Representa el crecimiento o descenso en la serie de tiempo, durante un periodo extenso.
2. **Componente Cíclico:** Cualquier secuencia de puntos recurrente por encima y por debajo de la línea de tendencia que dura más de un año puede atribuirse al componente cíclico de las series de tiempo. Es la fluctuación con forma de onda alrededor de la tendencia.
3. **Componente Estacional:** Representa cualquier patrón que se repite con regularidad y tiene duración menor a un año.
4. **Componente Irregular:** Factor residual que incluye las desviaciones de los valores de serie de tiempo reales de aquellos esperados según los efectos del componente cíclico, de tendencia y estacional. Este componente representa la variabilidad aleatoria en las series de tiempo y es resultado de factores a corto plazo, imprevistos y no recurrentes que afectan a la serie de tiempo.
Es impredecible.

Los patrones se identifican examinando los coeficientes de autocorrelación de una variable en diferentes retrasos de tiempo.

¿Los datos muestran una tendencia?

Si una serie muestra una tendencia, hay una relación significativa entre los valores sucesivos de la serie de tiempo. Los coeficientes de autocorrelación son usualmente grandes para varios de los primeros retrasos de tiempo y luego, conforme se incrementa el número de retrasos, caen gradualmente hacia cero.

¿Los datos son estacionales? Si una serie es estacional las observaciones de la misma posición, en diferentes periodos estacionales, tienden a estar relacionadas. Si se analizan datos trimestrales que tienen un patrón estacional, los primeros trimestres tienden a parecerse, los segundos trimestres tienden a parecerse, y así sucesivamente, y habrá un coeficiente de autocorrelación significativo en el retraso de tiempo 4.

Error de Pronóstico

La diferencia que existe entre el valor de la variable (x_t) y su valor pronosticado (f_t) en el momento t , es decir $e_t = x_t - f_t$, y nos da una estimación de la precisión del valor pronosticado. Es a nivel de un solo dato y el signo es importante, ya que indica la dirección del error. Si es positivo, el pronóstico fue demasiado bajo. Si es negativo, el pronóstico fue demasiado alto. Si es cero, el pronóstico fue perfecto.

Precisión del Pronóstico

Indica qué tan cercanos están los valores estimados respecto a los reales.

Existen varias métricas para medir la precisión del método de pronóstico adoptado, podemos usar el *Error Cuadrado Medio (EMC)*, la *Desviación Media Absoluta (MAD)* o el *Error Porcentual Absoluto Medio (MAPE)*.

EMC → Promedio del cuadrado de los errores. Este método penaliza los desvíos más grandes.

$$EMC = \frac{\sum_{i=1}^N (x_i - f_i)^2}{N} \quad N = \text{número de observaciones pronosticadas}$$

MAD → Promedio de los valores absolutos de los errores.

$$MAD = \frac{\sum_{i=1}^N |x_i - f_i|}{N} \quad N = \text{número de observaciones pronosticadas}$$

MAPE → Promedio del error absoluto del periodo dividido por el valor real observado en ese periodo y multiplicado por 100 para expresarlo como porcentaje. Es muy útil para comparar la exactitud de un método o más en series completamente diferentes.

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{x_i - f_i}{x_i} \right| (100)$$

Las medidas de precisión son siempre valores positivos. Un valor de precisión más bajo indica un pronóstico más preciso.

Método del Pronóstico del Último Valor

$$f_{t+1} = x_t$$

Cuando las condiciones cambian con rapidez, quizás el último valor sea el único dato relevante para pronosticar el siguiente valor.

Método del Promedio

En lugar de usar una muestra de tamaño 1, usa todos los datos y se obtiene un promedio de la serie:

$$f_{t+1} = \frac{\sum_{i=1}^t x_i}{t}; \quad \text{donde } t \text{ representa el número de periodos transcurridos.}$$

Es excelente si el proceso es muy estable.

Método de Promedios Móviles

Obtiene el promedio de los datos de los últimos n periodos:

$$f_{t+1} = \frac{\sum_{i=t-n+1}^t x_i}{n}$$

La ventaja de este método es que usa varias observaciones de datos recientes, pero todas las observaciones tienen el mismo peso.

Método de Promedio Móvil Ponderado

Asignamos pesos diferentes a las observaciones promediadas:

$$f_{t+1} = \sum_{i=t-n+1}^t p_i x_i, \quad \text{para } 0 \leq p_i \leq 1 \text{ y } \sum_{i=t-n+1}^t p_i = 1$$

La suma de los pesos debe ser igual a 1.

Método de Suavizado Exponencial

Es un caso especial del método de Promedio Móviles Ponderados, en el cual sólo seleccionamos el peso (α) que le corresponde a la observación más reciente.

$$f_{t+1} = \alpha x_t + (1 - \alpha)f_t \quad 0 < \alpha < 1, \quad \alpha \text{ se llama constante de suavizado}$$

Así el pronóstico es una suma ponderada de la última observación y el pronóstico anterior.

El pronóstico de la suavización exponencial para cualquier periodo es también un promedio ponderado de todos los valores reales previos.

Un valor bajo de la constante de suavizado hace que el pronóstico reaccione de manera más lenta a los cambios, por otro lado, un valor más alto es más sensible, pero podría reaccionar ante simples movimientos aleatorios.

Si la serie tiene una variabilidad aleatoria considerable, es preferible utilizar un valor pequeño para la constante de suavización. Como gran parte del error de pronóstico se debe a la variabilidad aleatoria, un α pequeño evita una reacción exagerada que ajuste los pronósticos demasiado rápido. Para una serie con poca variabilidad, valores más grandes de α permiten ajustar rápidamente los pronósticos cuando ocurren errores de pronóstico y por lo tanto el pronóstico reacciona más rápido ante condiciones cambiantes.

Pronóstico en Presencia de Tendencia

Podemos utilizar el método *Proyección de Tendencia*. Este ajusta una recta de tendencia a una serie de observaciones históricas y luego la utiliza para obtener pronósticos a mediano y largo plazo.

Una recta de tendencia es una ecuación de regresión con el tiempo como variable independiente. La forma de la ecuación de la recta de tendencia lineal es:

$$\hat{y} = b_0 + b_1 x, \text{ donde}$$

$\hat{y}$ = valor pronosticado
 b_0 = ordenada al origen
 b_1 = pendiente de la recta
 x = periodo (es decir $x = 1, 2, 3, \dots, n$)

Utilizamos el método de regresión de mínimos cuadrados para encontrar los coeficientes que minimizan la suma de los cuadrados de los errores y de esta manera se minimiza el error cuadrático medio (ECM):

$$b_1 = \frac{\sum x_i y_i - \left(\frac{\sum x_i \sum y_i}{n} \right)}{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} \quad b_0 = \bar{y} - b_1 \bar{x}$$

Pronóstico en Presencia de Tendencia y Estacionalidad

Cálculo de los índices estacionales con Promedio Móvil Centrado

Analizar los datos en términos de meses o trimestres facilita la detección de los patrones estacionales. Es frecuente utilizar un índice estacional en los modelos de pronósticos multiplicativos, para realizar un ajuste en la predicción, cuando existe una componente estacional.

La eliminación del efecto estacional de una serie se conoce como desestacionalización; eliminar este efecto nos ayuda a identificar la componente de tendencia.

Un índice estacional indica la comparación de una estación dada (como mes o trimestre) y una estación promedio. Cuando no hay una tendencia, el índice se determina dividiendo el valor promedio para una estación específica entre el promedio de todos los datos. Así, un índice de 1 significa que la estación es promedio.

Los pasos para obtener los índices estacionales basados en los PMC son:

1. Calcular el PMC para cada observación (cuando sea posible).

2. Calcular la Razón Estacional (RE) realizando el cociente entre cada observación y el PMC (observación/PMC para esa observación).
3. Promediar las razones estacionales para obtener los índices estacionales (IE).
4. Si la suma de los IE no es igual al número de estaciones (n), multiplicar cada índice por el cociente entre el número de estaciones y la suma de los IE ($n/\sum IE$).

Este método tiene la ventaja de que capta mejor el componente estacional si hay muchos datos y tendencia. Pero requiere más años de observaciones (mínimo 3-4 ciclos completos) para que funcione bien. Con pocos datos puede distorsionar.

Cálculo de los índices estacionales con promedios simples anuales.

Calculamos un índice estacional para cada año y luego promediamos los índices de cada estación para eliminar la componente irregular.

Los pasos para obtener los índices estacionales basados en este método son:

1. Calcular el promedio anual.
2. Dividir cada observación estacional por el promedio anual.
3. Promediar las observaciones de cada estación.

Este método funciona bien con pocos años de datos. Pero es más sensible a valores atípicos y a tendencias fuertes, porque no las elimina.

Descomposición del Pronóstico con componentes de Tendencia y Estacionalidad

Eliminamos la estacionalidad de los datos dividiendo cada número entre su índice estacional. Luego, se estima la recta de tendencia usando los datos sin estacionalidad.

Con esta ecuación calculamos el pronóstico basado en la tendencia, y luego se lo ajusta con el índice estacional multiplicando cada valor por el índice estacional correspondiente.

En resumen, los pasos de este método son:

1. Calcular los índices estacionales usando alguno de los métodos vistos.
2. Eliminar la estacionalidad de los datos dividiendo cada número entre su índice estacional.
3. Encontrar la ecuación de la recta de tendencia empleando los datos sin estacionalidad.
4. Pronosticar para períodos futuros con la recta de tendencia.
5. Multiplicar el pronóstico de la recta de tendencia por el índice estacional correspondiente.

Señal de Control

Lo usamos para monitorear y garantizar que un modelo de pronóstico siga siendo confiable.

Control de Errores de Pronóstico

Si la técnica utilizada es razonablemente precisa, los errores suelen distribuirse aproximadamente de manera normal alrededor de cero. Bajo esta condición, hay un 0,95 de probabilidad de que la observación real se ubique dentro de aproximadamente dos desviaciones estándar del pronóstico. Para estimar la desviación estándar de los errores, podemos usar el MAD mediante la relación $Se = 1,25(MAD)$.

De esta manera, podemos afirmar que, con un 0,95 de probabilidad, los valores reales se ubicarán dentro del rango:

$$\text{Valor pronosticado} \pm 2 (1,25) \text{ MAD}$$

Los errores que caen dentro de este rango indican que no hay motivo de alarma, mientras que errores fuera de los límites pueden señalar un cambio en el patrón.

Señal de Rastreo

Es otra técnica utilizada definida como el cociente entre los errores acumulados (sesgo) y el MAD:

$$\text{Señal de Rastreo} = \frac{\sum e_t}{MAD}$$

Entonces, si la señal está cerca de 0, los errores se compensan y en general el modelo está bajo control. En cambio, si la señal se aleja significativamente de 0, existe un sesgo y el modelo tiende a equivocarse siempre en la misma dirección.

Para interpretar la señal de rastreo se establecen límites de control, por ejemplo, ± 4 MAD, que funcionan como una especie de “alarma”.

Métodos Causales

Utilizamos como método de pronóstico causal el *análisis de regresión* para desarrollar una ecuación matemática que relacione la variable que queremos pronosticar con otras variables que se supone la influyen o explican.

Métodos Cualitativos de Pronóstico

Estos métodos se consideran adecuados cuando se espera que el patrón de comportamiento histórico de las series de tiempo no continúe en el futuro. El uso de técnicas de pronóstico cualitativo aumenta cuando los datos históricos son escasos o cuando se cree que éstos son parcialmente irrelevantes.

Método Delphi

El método Delphi intenta elaborar pronósticos por medio de un “consenso de grupo”.

Las opiniones de cada experto se resumen y cada miembro del grupo es informado de las posiciones de sus colegas anónimos. Luego, se le solicita a cada uno de los participantes que reconsideren y analicen su respuesta previa a la luz de la información proporcionada por el grupo. Este proceso continúa hasta que el coordinador considera que se ha llegado a cierto grado de consenso.

El objetivo es obtener una pluralidad de opiniones con las cuales coincida la mayoría de los expertos.

Cualquier procedimiento Delphi tiene cuatro características fundamentales: anonimato, iteración, retroalimentación controlada y agregación de respuestas del grupo.

Juicio Experto

En este caso cada experto considera la información que cree influirá en la variable de interés que se quiere predecir, luego combinan sus conclusiones en un pronóstico. No se utiliza un modelo formal.

Redacción de Escenarios

Consiste en la elaboración de escenarios conceptuales del futuro con base en un conjunto de supuestos o hipótesis bien definidas. Estos conjuntos de hipótesis proporcionan escenarios distintos. La nueva tecnología, los cambios demográficos y el cambio en las demandas del consumidor son, entre otros, los factores que se consideran y entrelazan. Se establece cuál es el escenario más probable, junto con uno o más escenarios menos probables, pero posibles. Una vez seleccionado el escenario más probable, se inicia una etapa de debate.

Unidad N°8: Gestión de Stock

Para gestionar stock utilizamos modelos de administración de inventarios. El objetivo es reducir al mínimo los costos relacionados con el mantenimiento de existencias de mercadería y al mismo tiempo poder cumplir con la demanda.

Cada modelo contempla una realidad diferente, por eso hay que caracterizar adecuadamente el problema para poder seleccionar el modelo correcto.

Los elementos que hay que tener en cuenta a la hora de armar una política de inventario son:

- **Características de la demanda.** ← La demanda puede ser determinista o aleatoria. Si es determinista, entonces es también conocida y a una tasa constante en el tiempo. Si es aleatoria, puede ser una variable discreta o continua.
- **Costos relevantes.**
 - **Costo de pedido.** ← Gastos de emitir una orden de pedido o iniciar un lote de producción. Es un costo fijo e independiente del número de unidades pedidas o fabricadas.
 - **Costo de almacenamiento.** ← Costo de mantener mercadería almacenada. Se expresa por unidad de producto para el periodo total de análisis o por unidad de producto por unidad de tiempo.
 - **Costo de ruptura o agotamiento.** ← Costo que se genera cuando la demanda supera la cantidad de mercadería en inventario. Puede ser por pedidos pendientes o pérdidas de venta. Se expresa por unidad de producto para el periodo total de análisis o por unidad de producto por unidad de tiempo.
- **Posibilidad de admitir faltantes en almacén.**
- **Retrasos en el ingreso de los pedidos.** ← Hay que tener en cuenta el periodo que pasa entre el momento de hacer el pedido o iniciar un lote de producción y el momento en que esté disponible la mercadería.
- **Precio del producto.** ← El precio del producto puede variar según el tamaño del pedido.
- **Posibilidad de aceptar pedidos pendientes.**
- **Modalidad de ingreso del pedido.** ← El pedido puede ingresar al almacén en un solo lote o de forma parcial a lo largo de un periodo de tiempo.

Clasificación ABC


Uno de los primeros pasos para administrar stock es hacer un análisis ABC. Por medio de este análisis podemos determinar qué artículos representan la mayor parte de la inversión y si se justifica mantener invertidos estos recursos.

El Sistema ABC ordena los artículos que componen el inventario, en base al porcentaje que su valor monetario representa en el total y los clasifica en tres grupos:

- **Grupo A.** ← Se incluyen aquellos artículos que contribuyen al 80% del valor monetario acumulado y generalmente constituyen alrededor del 20% de los ítems. Se aplica un estricto control.
- **Grupo B.** ← Aquellos artículos que verifican valores monetarios porcentuales entre el 10% y 15%, y comprenden alrededor del 25% de todos los ítems. Se aplica un control moderado.
- **Grupo C.** ← Aquellos artículos que corresponden al 5% del valor monetario porcentual y comprenden más o menos el 55% de los ítems. Se aplica un grado mínimo de control.

Procedimiento:

1. Determinar la participación monetaria de todos los ítems en el valor total del inventario.
2. Tabular los artículos en orden descendente según el porcentaje de dinero invertido y calcular el acumulado.
3. Calcular el porcentaje que cada ítem representa en el total y luego el acumulado.
4. Graficar la curva ABC del porcentaje acumulado del uso del dinero en función del porcentaje acumulado de ítems.



De esta manera se espera que una cantidad reducida de ítems que se encuentran en la parte superior de la clasificación serán parte del grupo A, y requerirán la mayor atención por parte de la gerencia; la mayor cantidad de ítems que se encuentran en la parte inferior de la clasificación son asignados al grupo C y requerirán una mínima atención de la gerencia y la cantidad restante de ítems hará parte del grupo B y requieren mediana atención.

Simbología a utilizar

T: período de análisis.

N: demanda total en el período de análisis.

t: unidad de tiempo.

h: demanda en la unidad de tiempo o tasa de demanda.

S: nivel máximo de stock.

q: cantidad a pedir o tamaño del lote de producción/compra.

t_1 : periodicidad de efectuar los pedidos o iniciar las corridas de producción.

τ : tiempo que transcurre entre el momento de realización del pedido y su ingreso al almacén.

Período de adelanto o de reaprovisionamiento.

v : cantidad de pedidos (o corridas de producción) a efectuar en el período de análisis T .

p_i : costo unitario de producción o adquisición del producto.

C_s : costo de almacenar una unidad de producto en la unidad de tiempo.

C_p : costo de efectuar un pedido o iniciar un lote de producción.

C_r : costo de ruptura por unidad de producto y por unidad de tiempo.

C_f : costo por unidad de producto faltante al final del período de análisis.

C_e : costo por unidad de producto excedente o sobrante al final del período.

CT : costo total variable de la política de inventarios.

Modelos Determinísticos

Modelo 1 de Universo Cierto o Modelo Sin Ruptura o Modelo CEP o Modelo Básico o como diga el profe.

Supuestos

1. La demanda es conocida y se produce a una tasa constante en el tiempo.
2. No se permiten rupturas de stock.
3. El volumen del pedido o lote de producción es constante.
4. Se emite una orden de pedido/producción cuando el nivel del inventario llega a cero.
5. El pedido o lote de producción ingresa instantáneamente, es decir que el periodo de adelanto es cero.
6. La mercadería se recibe en un solo lote.
7. El horizonte de tiempo es infinito y continuo.
8. El precio de costo/producción es constante, no importa la cantidad que se pida/fabrique.
9. Los costos se consideran constantes en el horizonte de tiempo.

Los costos relevantes en este modelo son: C_p y C_s .

Gráfica de comportamiento del inventario




Gráfico 4

Desarrollo

El objetivo es determinar la cantidad óptima de pedido (q^*), para minimizar los costos totales (CT) y se cumpla con la demanda del producto (N).

Dado que la tasa de demanda h es constante por unidad de tiempo, podemos establecer las siguientes relaciones:

$$h = \frac{N}{T} = \frac{q}{t_1}; \quad t_1 = \frac{Tq}{N}; \quad v = \frac{N}{q}$$

Se construye la función objetivo que queremos minimizar, esta es una función de costo total variable (CT), teniendo en cuenta que los costos relevantes son C_s y C_p .

$$CT = CT_s + CT_p$$

donde:

$$CT_s = C_s q/2 T \quad CT_p = C_p v$$

entonces:

$$CT = C_s \frac{Tq}{2} + C_p \frac{N}{q} \quad (3)$$


q^* se obtiene de la siguiente fórmula:

$$q^* = \sqrt{\frac{2 C_p N}{C_s T}}$$

Conociendo el valor óptimo de q , podemos reemplazarlo en (3) y obtener el $CT(q^*)$:

$$CT(q^*) = C_s T \frac{\sqrt{2C_p N}}{2} + \frac{C_p N}{\sqrt{2C_p N}} = \sqrt{2 C_p N T C_s}$$

En el valor óptimo de q , se verifica que el costo total de almacenamiento se iguala al costo total de hacer pedidos. Lo podemos ver en el siguiente gráfico:



Tip: Si en un ejercicio te dan por ejemplo el CT_s , el q y no te dan mas datos pero te dicen que es una política **óptima**, entonces **$CT_p = CT_s$ por estar en la política óptima**, no es que falten datos, es medio tramposa la cosa en ese caso, para que no se coman el amague.

Modelo 2 de Universo Cierto o Modelo Con Ruptura

Cuando en situaciones donde se permitan faltantes o rupturas de stock, podemos aplicar este modelo. El periodo que transcurre entre pedidos se alarga y por lo tanto, el número total de pedidos y el costo total de pedidos son menores. Además, el costo de almacenamiento también disminuye, ya que el nivel de inventario es menor al permitir faltantes o rupturas. No obstante, a este modelo se le agrega un costo por la falta de mercadería. El objetivo es equilibrar los *costos de ruptura*, que son crecientes, con los costos decrecientes de pedidos y almacenamiento.

Supuestos

1. La demanda es conocida y se produce a una tasa constante en el tiempo.
2. Se permiten rupturas o faltantes de stock.
3. El volumen del pedido es constante.
4. El pedido se recibe instantáneamente, es decir que el periodo de adelanto es cero.
5. La mercadería se recibe en un solo lote.
6. El horizonte de tiempo es infinito y continuo.
7. El costo del producto es constante, no importa la cantidad que se pida.
8. Los costos se consideran constantes en el horizonte de tiempo.
9. La demanda que se produce cuando no hay stock no se pierde, se lo toma como pedidos pendientes que se satisfacen al llegar el reabastecimiento.

$$CTp = Cp \frac{N}{q}$$

$$CTr = Cr \frac{T(q-S)^2}{2q}$$

Entonces:

$$CT = Cs \frac{TS^2}{2q} + Cp \frac{N}{q} + Cr \frac{T(q-S)^2}{2q}$$

Para obtener el valor de q y S que hagan óptima CT se usan las siguientes fórmulas:

$$q^* = \sqrt{\frac{2 Cp N}{Cs T}} \sqrt{\frac{Cs + Cr}{Cr}} \quad \text{y} \quad S^* = \sqrt{\frac{2 Cp N}{Cs T}} \sqrt{\frac{Cr}{Cs + Cr}}$$

Observemos que cuanto mayor sea el costo de mantenimiento de inventario con respecto al costo de los pedidos pendientes, conviene mantener un nivel de inventario más bajo y, por el contrario, cuanto mayor importancia tenga el costo por faltantes, el nivel de inventarios será más alto y menor la ruptura.

De acuerdo con esto, a medida que aumenta el costo de ruptura el lote óptimo de este modelo se acerca al valor calculado con el modelo CEP.

También puede observarse que, siempre que la situación lo permita, es conveniente utilizar el modelo con agotamientos planeados, ya que este produce un costo total menor que usando el modelo CEP.

Relación entre el Modelo 1 y el Modelo 2

En el modelo 1 $\Rightarrow q = S$

En el modelo 2 $\Rightarrow q \neq S$

En S del segundo modelo, aparece lo que se llama *tasa de ruptura* (ρ), este término quien hace la diferencia entre el inventario máximo en ambos modelos:

$$\sqrt{\frac{Cr}{Cr + Cs}} \quad \text{y es}$$

Si tomamos límite para $Cr \rightarrow \infty$, la tasa de ruptura se hace igual a 1, por lo que podemos afirmar lo siguiente: **“el modelo 1 es un caso particular del modelo 2, cuando el costo de ruptura es inmensamente alto”**. Es decir que, cuando el costo de ruptura es muy grande ($Cr \rightarrow \infty$), el modelo 2 se transforma en el modelo 1, que justamente no admite rupturas porque tienen un costo imposible de afrontar.

Modelo con Reabastecimiento Uniforme

Al colocar una orden, las piezas van ingresando al inventario a una tasa constante durante un cierto periodo de tiempo. Esta tasa, a la cual se fabrica el producto, debe ser mayor que la tasa de demanda; de lo contrario no se podría cumplir con la demanda.

Supuestos

1. La demanda es conocida y se produce a una tasa constante en el tiempo llamada h .
2. El lote se produce a una tasa de producción conocida de a unidades por unidad de tiempo.
3. Los bienes ingresan al almacén a una tasa constante a que debe ser mayor a la tasa de demanda h , de otra manera no existiría inventario, es decir $a > h$.
4. No se permiten rupturas de stock.
5. El volumen del lote de producción (q) es constante.
6. Se emite una orden de pedido cuando el nivel del inventario llega a cero.
7. El costo de producción es constante y no depende del número de unidades del lote.

Los costos relevantes en este modelo son:

C_p = Costo de emisión de la orden de producción.

C_s = Costo de mantener almacenada una unidad de producto en una unidad de tiempo.


Gráfica de comportamiento del inventario

Gráfico 7

Observemos que la periodicidad de efectuar los pedidos (t_1) se divide en dos tiempos, el tiempo durante el cual ingresa y se consume mercadería (t_4) y el tiempo durante el cual solamente se consume (t_5), es decir: $t_4 + t_5 = t_1$. Durante el periodo de reabastecimiento (t_4), el inventario crece con una tasa igual a la diferencia entre las tasas de demanda y abastecimiento.

Desarrollo

Se desarrolla el modelo del lote de producción a partir de una función de costo total que contempla el costo total de almacenamiento, más el costo total de preparación de la producción, de manera similar a la desarrollada en el primer modelo.

$$CT = CT_p + CT_s$$

Considerando que:

Durante t_4 la mercadería se produce a una tasa a , por lo que al final de este periodo se habrá completado la producción del lote completo q , es decir:

$$q = a t_4; \text{ despejando } t_4 = q/a;$$

$$t_1 = t_4 + t_5; \quad t_5 = t_1 - t_4$$

Debido a que durante el período t_4 ingresa y sale mercadería, la tasa a la cual se acumula el inventario es $(a - h)$ por lo que el stock máximo, que se da al final del periodo t_4 , será:

$$S = (a - h) t_4; \text{ reemplazando a } t_4 \quad S = (a - h) \left(\frac{q}{a} \right); \quad S = q \left(1 - \frac{h}{a} \right)$$

Entonces, reemplazando en la función de Costo Total (CT), queda:

$$CT(q) = C_p \frac{N}{q} + C_s \frac{q}{2} T \left(1 - \frac{h}{a} \right)$$

Si queremos obtener el q^* , aplicamos la siguiente fórmula:

$$q^* = \sqrt{\frac{2 C_p N}{C_s T \left(1 - \frac{h}{a} \right)}}$$

Si comparamos este modelo con reabastecimiento uniforme con el primer modelo, podemos observar que se realizan pedidos más grandes y los costos son menores. Esto es así, porque durante el periodo t_4 algunas unidades que se reciben se distribuyen inmediatamente, lo cual reduce los costos de almacenamiento.

Nivel de Reorden y Stock de Seguridad

Se da cuando existe un lapso de tiempo entre el momento de realizar el pedido y el momento en que éste ingresa al almacén. Este lapso de tiempo se llama *periodo de adelanto o reabastecimiento* (τ).

Ahora, tenemos la necesidad de fijar un *nivel de reorden*, es decir, el nivel de inventario que indica el momento de realizar el pedido y este es distinto de cero.

Se pueden presentar dos situaciones: que τ sea determinista o que τ sea aleatorio con distribución de probabilidad conocida.

Periodo de Adelanto Determinista


Modelo Sin Ruptura

Fijamos un nivel de reorden igual a la demanda (m) en el período τ . Como la demanda (h) es conocida y constante, entonces el nivel de reorden (x) será:

$$x_0 = m = h \cdot \tau$$

El punto de reorden (t_0) será:

$$t_0 = t_1 - \tau$$



Modelo Con Ruptura

Tenemos dos casos:


- Caso en que el momento de realizar el pedido ($t_1 - \tau$) se encuentra dentro del período que hay stock (t_2):
El nivel de reorden se calcula como:
 $x = h (\tau - t_3)$
- Caso en que el momento de realizar el pedido ($t_1 - \tau$) se encuentra dentro del período que no hay stock (t_3):
El nivel de reorden se calcula de la misma manera que en el caso a)

Si el resultado es positivo, indicará el nivel de stock que nos alerta de realizar el pedido, mientras que si es negativo nos mostrará el nivel de ruptura que advierte cuando realizar el pedido.

Modelo Con Reabastecimiento Uniforme

Hay dos casos:


- Caso en que el momento de realizar el pedido ($t_1 - \tau$) se encuentra durante el período de demanda (t_5):



El nivel de reorden se calcula como:

$$x = h \tau$$

- Caso en que el momento de realizar el pedido ($t_1 - \tau$) se encuentra durante el período de ingreso de mercadería (t_4)




El nivel de reorden se calcula como:

$$x = (a - h) (t_1 - \tau)$$

Periodo de Adelanto Aleatorio

Modelo Sin Ruptura

Gráficamente, el nivel de reorden x que permite un nivel de confianza de $1 - \alpha$ es el siguiente:



Como hemos supuesto que τ y por lo tanto m siguen una distribución normal, entonces, dado un nivel de confianza $1 - \alpha$, podremos determinar el nivel de reorden como sigue:

$$z_{1-\alpha} = \frac{x - \bar{m}}{\sigma_m}$$

En consecuencia:

$$x_0 = \bar{m} + z_{1-\alpha} \cdot \sigma_m$$

Donde:

$$\bar{m} = h \cdot \bar{\tau}$$

$$\sigma_m = h \cdot \sigma_{\tau}$$

Podemos observar que ahora el nivel x está formado por m , más una cierta cantidad representada por $z_{1-\alpha} \sigma_m$. Esta cantidad se llama *stock de seguridad*, y tiene como función cubrir los excesos de la demanda real, por encima de la demanda media, en el periodo de retardo.

Modelo Con Ruptura

Si τ es aleatorio con distribución normal, entonces:

$$x_0 = h \cdot \bar{r} - h \cdot t_3 + z_{1-\alpha} h \sigma_r$$

Cuando x_0 es positivo nos está indicando el nivel de inventario que nos alerta de realizar el pedido o iniciar el lote de producción y si x_0 es negativo nos está indicando un nivel de ruptura.

Modelo con Reabastecimiento Uniforme

Tenemos los mismos dos casos:

- a) Si el pedido ingresa durante el periodo en el que se produce el almacenamiento (t_4):

$$x_0 = (a-h)t_1 - \left[(a-h) \bar{r} + z_{1-\alpha} (a-h) \sigma_r \right]$$

- b) Si el pedido ingresa durante el periodo de solo consumo (t_5):

$$x_0 = \bar{m} + z_{1-\alpha} \sigma_{ms} = h \bar{r} + z_{1-\alpha} h \sigma_r$$

Modelo Con Descuentos Por Compras En Cantidades

Ocorre frecuentemente que los proveedores ofrecen descuentos si los pedidos son suficientemente grandes, por lo que el precio unitario va disminuyendo a medida que se incrementa el tamaño del lote.

Esta condición, obliga a que se incorpore el precio del producto en la función de costo total variable. Además, al ser el precio discontinuo, el CT también lo será. En estos casos, también suele ocurrir que el costo de almacenamiento deja de ser constante, porque generalmente una parte de este costo está en relación directa con el precio del producto.

Desarrollo

El costo de almacenamiento se hace una función:

$C_s = a + b p_i$ siendo p_i el precio del producto.

La función de Costo Total se calcula de la siguiente forma:

$CT = CT_p + CT_s +$ demanda total valuada según el precio del producto

Quedándonos la siguiente fórmula:

$$CT(q, p_i) = C_p \frac{N}{q} + (a + b p_i) \frac{T q}{2} + p_i N$$

Para cada valor de p_i , existirá una función de Costo Total, la que dependerá sólo de q .

En cada función de Costo Total podremos calcular a q_i^* de la siguiente forma:

$$q_i^* = \sqrt{\frac{2 C_p N}{(a + b p_i) T}}$$


El procedimiento consta de dos etapas:

- Etapa 1: Calcular q_i^* para cada intervalo de precio, comenzando por el intervalo que tiene el menor precio hasta encontrar un q_i^* comprendido en el intervalo de cantidades.
- Etapa 2: Comparar las funciones de costo total para el q_i^* encontrado y las cantidades (q) mínimas que permiten acceder a los descuentos en el precio del producto.

Pasos:

1. Comenzamos por el intervalo de menor precio y calculamos el q_i^* con ese precio. Si q_i^* está comprendido en ese intervalo entonces éste es el volumen óptimo de pedido. FIN DEL PROCEDIMIENTO
2. Si q_i^* no está en ese intervalo, continuamos con el siguiente intervalo y si está comprendido, calculamos el costo total para ese valor de q_i^* y para la menor cantidad con la que se puede acceder al descuento; el costo total menor indicará el volumen óptimo (q^*).
3. Si q_i^* no está en ese intervalo, repetimos el paso 2 hasta encontrar un q_i^* comprendido en un intervalo y comparamos el costo total para ese valor con los que surgen de considerar las cantidades mínimas para acceder a cada descuento.

Gráfica de comportamiento del inventario



Modelo 1 de Universo Aleatorio

Supuestos

En este modelo suponemos que se debe hacer una compra, al inicio de un periodo predeterminado, para satisfacer una demanda aleatoria que se presentará durante dicho periodo. Es por eso que decimos que para este modelo: $T = t_1$.

Supondremos además que la demanda acumulada al momento t es lineal.

Los costos a considerar en este modelo son:


C_e = Costo por cada unidad de producto excedente al final del periodo.

C_f = Costo por cada unidad de producto faltante al final del periodo.

El costo de pedido no se considera ya que se pide una única vez en el periodo.

El criterio de optimización que se utiliza es el de minimizar el valor esperado del costo total.

Gráfica del comportamiento del inventario

Desarrollo

Para determinar la cantidad óptima a pedir en cada periodo se deben estimar:

1. La distribución de probabilidad de la demanda.
2. C_e = costo por unidad excedente y C_f = costo por unidad faltante.
3. Identificar la cantidad óptima de pedido (q^*) teniendo en cuenta si la demanda es una variable discreta o continua.

☞ Si la demanda es una variable discreta:

$$P(N \leq q - 1) < \frac{C_f}{C_e + C_f} \leq P(N \leq q^*)$$

☞ Si la demanda es una variable continua:

$$P(N \leq q^*) = \frac{C_f}{C_e + C_f}$$

Si queremos calcular el costo esperado de tomar la decisión de comprar cada día q unidades, lo hacemos utilizando la fórmula:

$$\overline{CT}(q, N) = C_e \sum_{N=0}^q (q - N) P_N + C_f \sum_{N=q+1}^{\infty} (N - q) P_N$$

Modelo 2 de Universo AleatorioSupuestos

1. Demanda (N) es una variable aleatoria discreta con distribución de probabilidad (P_N) conocida.
2. Costos relevantes:
 C_s = costo de mantener una unidad en el inventario por unidad de tiempo.
 C_r = costo por unidad de ruptura y por unidad de tiempo
3. Periodo único de análisis $T = t_1$
4. El comportamiento de la demanda acumulada hasta el momento t (y en consecuencia del inventario) es lineal.